

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG

BÁO CÁO CUỐI KỲ THỰC TẬP

**Xây dựng Equity Sentiment Index cho thị trường
chứng khoán Việt Nam và phân tích tác động đến
VN-Index**

Sinh viên thực hiện: Bùi Doãn Khang

Mã số sinh viên: 20235950

Lớp: Global-ICT (IT-E7)

Đơn vị thực tập: Công ty Cổ phần Công nghệ Thông tin 3T

Bộ phận: D&A

Vị trí: Thực tập sinh Data Scientist

Người hướng dẫn: Vũ Đức Hải

Thời gian thực tập: 18/03/2026 – 30/05/2026

Kỳ thực tập: 2026/3T/TT/01

Hà Nội, 05/2026

Table of contents

1	Lời cảm ơn	4
2	Tóm tắt	5
3	Giới thiệu	6
3.1	Bối cảnh	6
3.2	Mục tiêu thực tập	6
3.3	Phạm vi báo cáo	7
4	Tổng quan dữ liệu và cấu trúc pipeline	8
4.1	Kích thước dữ liệu sau các bước xử lý	8
4.2	Luồng xử lý tổng quát	9
5	Xử lý dữ liệu giá lịch sử	10
5.1	Mục tiêu xử lý Historical_price	10
5.2	Kiểm tra chất lượng dữ liệu giá	10
5.3	Xử lý cột symbol	11
5.4	Làm sạch và tạo feature	11
5.5	Tách dữ liệu VN-Index	12
6	Xử lý dữ liệu tin tức	13
6.1	Mục tiêu xử lý News	13
6.2	EDA dữ liệu tin tức thô	13
6.3	Làm sạch metadata	14
6.4	Lọc tin tức cổ phiếu	14
6.5	Làm sạch nội dung bài báo	14
6.6	Tách từ tiếng Việt (Tokenize Vietnamese text)	15
7	Trích xuất candidate terms và xây dựng dictionary sentiment	16
7.1	Trích xuất candidate n-gram	16
7.2	Xây dựng dictionary sentiment tài chính	16
7.3	Lý do cần dictionary theo ngữ cảnh tài chính	17
8	Gán sentiment score cho bài báo (basic solution)	18
8.1	Input và output	18
8.2	Công thức sentiment score (fundamental formula)	18
8.3	Quy tắc gán nhãn content	19

9	Fine-tune mô hình PhoBERT cho sentiment tài chính (1st version)	21
9.1	Mục tiêu fine-tune	21
9.2	Input của mô hình	21
9.3	Train/test split	22
9.4	Kết quả đánh giá mô hình	22
10	Xây dựng Equity Sentiment Index (rule-based approach)	24
10.1	Ý tưởng	24
10.2	Daily sentiment index	24
10.3	Weekly sentiment index	25
10.4	Monthly sentiment index	25
10.5	Chuẩn hóa z-score	26
11	Xử lý VN-Index và phân tích tác động	27
11.1	Tạo weekly return cho VN-Index	27
11.2	Tạo biến future return	28
12	Abnormal return	29
12.1	Lý do dùng abnormal return	29
12.2	Hai cách tính expected return	29
12.2.1	Cách 1: Rolling mean expected return	29
12.2.2	Cách 2: Rolling AR(1)	30
12.3	Future abnormal return	30
13	Predictive regression	31
13.1	Mục tiêu	31
13.2	Target và predictor	31
13.3	Newey-West standard error	32
13.4	Kết quả hồi quy chính	32
14	Đánh giá pipeline hiện tại	33
14.1	Điểm mạnh	33
14.2	Hạn chế	33
14.3	Rủi ro sai lệch dữ liệu	33
15	Hướng phát triển	35
15.1	Cải thiện dictionary sentiment	35
15.2	Cải thiện sentiment score cho content	35
15.3	Cải thiện Equity Sentiment Index	36
15.4	Mở rộng phân tích tác động	36
15.5	Backtesting tín hiệu giao dịch (chưa hoàn thành)	36

15.6 Kết luận về những điểm làm được trong dự án	37
16 Công thức chính	38
16.1 Sentiment score bài báo	38
16.2 Sentiment index theo kỳ	38
16.3 Z-score sentiment index	38
16.4 Weekly return	38
16.5 Abnormal return	38
16.6 Predictive regression	38
17 Tài liệu tham khảo	39

CHƯƠNG 1

Lời cảm ơn

Trong quá trình thực tập tại Công ty Cổ phần Công nghệ Thông tin 3T, em đã có cơ hội tiếp cận một bài toán dữ liệu tài chính tương đối đầy đủ, bắt đầu từ dữ liệu giá lịch sử, dữ liệu tin tức tiếng Việt, xây dựng từ điển cảm xúc tài chính, huấn luyện mô hình NLP, cho đến tính toán chỉ số Equity Sentiment Index và thử nghiệm phân tích tác động đến VN-Index.

Em xin gửi lời cảm ơn tới anh Vũ Đức Hải và các anh chị trong bộ phận D&A đã hướng dẫn, góp ý và hỗ trợ em trong quá trình thực hiện. Những trao đổi trong giai đoạn thực tập giúp em hiểu rõ hơn cách một bài toán Data Science trong tài chính cần được triển khai: không chỉ dừng ở mô hình, mà còn cần dữ liệu sạch, định nghĩa biến rõ ràng, kiểm chứng định lượng và diễn giải kết quả thận trọng.

CHƯƠNG 2

Tóm tắt

Báo cáo này trình bày toàn bộ quá trình xây dựng pipeline xử lý dữ liệu phục vụ phân tích cảm xúc thị trường chứng khoán Việt Nam. Công việc được chia thành bốn nhóm chính:

1. Xử lý dữ liệu giá lịch sử trong thư mục `Historical_price`, bao gồm kiểm tra chất lượng dữ liệu, chuẩn hóa mã chứng khoán, lọc dữ liệu cần dùng, tạo bộ dữ liệu VN-Index và xây dựng return theo tuần.
2. Xử lý dữ liệu tin tức trong thư mục `News`, bao gồm làm sạch dữ liệu thô, lọc tin liên quan đến thị trường cổ phiếu, làm sạch nội dung, tách từ tiếng Việt, trích xuất candidate n-gram và xây dựng dictionary cảm xúc tài chính.
3. Gán nhãn sentiment cho nội dung bài báo, fine-tune mô hình PhoBERT trong ngữ cảnh tài chính, sau đó xây dựng Equity Sentiment Index theo ngày, tuần và tháng.
4. Phân tích tác động đến VN-Index trong thư mục `News_Vnindex`, gồm tạo weekly return, merge với weekly sentiment, tính abnormal return, chạy correlation và predictive regression.

Kết quả chính của pipeline hiện tại gồm: 126.576 bài báo tài chính đã được làm sạch và tách từ, 43.840 candidate terms trong dictionary cảm xúc tài chính, 5.037 quan sát sentiment index theo ngày, 731 quan sát theo tuần, và bộ dữ liệu merge giữa weekly sentiment với VN-Index gồm 722 tuần. Mô hình PhoBERT fine-tuned trên nhãn sentiment tài chính đạt accuracy khoảng 85,5% và macro F1 khoảng 82,0% trong lần kiểm thử. Kết quả phân tích tác động cho thấy sentiment có quan hệ yếu với return tuần kế tiếp, nhưng có tín hiệu âm rõ hơn ở horizon 4 tuần, đặc biệt với future abnormal return.

CHƯƠNG 3

Giới thiệu

3.1 Bối cảnh

Tin tức tài chính là một nguồn thông tin quan trọng phản ánh kỳ vọng, lo ngại và tâm lý của nhà đầu tư. Trong thực tế, giá tài sản tài chính không chỉ chịu ảnh hưởng bởi dữ liệu cơ bản như lợi nhuận doanh nghiệp, lãi suất, thanh khoản hay tăng trưởng vĩ mô, mà còn chịu tác động từ cách thị trường tiếp nhận và phản ứng với thông tin. Vì vậy, việc đo lường sentiment từ tin tức có thể bổ sung một lớp tín hiệu định lượng cho các bài toán phân tích thị trường.

Trong nghiên cứu quốc tế, hướng tiếp cận sử dụng văn bản để đo lường tâm lý thị trường đã được khai thác trong nhiều công trình. Tetlock (2007) chỉ ra rằng sắc thái tiêu cực trong truyền thông tài chính có quan hệ với biến động thị trường. Loughran và McDonald (2011) nhấn mạnh rằng các từ điển sentiment phổ thông có thể không phù hợp với ngữ cảnh tài chính, do nhiều từ mang sắc thái khác trong báo cáo tài chính và tin tức doanh nghiệp. Baker và Wurgler (2006) đề xuất cách nhìn sentiment như một chỉ báo tổng hợp phản ánh mức độ lạc quan hoặc bi quan của thị trường.

Với tiếng Việt, bài toán này có thêm một số khó khăn: dữ liệu tin tức không đồng nhất về nguồn, nội dung nhiều nhiễu, ngôn ngữ tài chính có nhiều cụm từ đặc thù, và các mô hình NLP tiền huấn luyện cần được điều chỉnh theo ngữ cảnh thị trường Việt Nam. Vì vậy, pipeline trong báo cáo này được thiết kế theo hướng kết hợp giữa xử lý dữ liệu, dictionary tài chính và fine-tune PhoBERT, một mô hình ngôn ngữ tiếng Việt được đề xuất bởi Nguyen và Nguyen (2020).

3.2 Mục tiêu thực tập

Dựa trên bảng theo dõi quá trình thực tập tại Công ty Cổ phần Công nghệ Thông tin 3T, mục tiêu của kỳ thực tập gồm:

Nhóm mục tiêu	Nội dung	Kết quả kỳ vọng
Xử lý dữ liệu tin tức	Tiền xử lý và khám phá dữ liệu tin tức thị trường cổ phiếu Việt Nam	Dataset tin tức cổ phiếu được phân loại, làm sạch và EDA đầy đủ

Nhóm mục tiêu	Nội dung	Kết quả kỳ vọng
Phân tích sentiment	Xây dựng mô hình NLP phân tích cảm xúc tin tức thị trường cổ phiếu	Mô hình sentiment đạt accuracy từ 80% trên tập kiểm thử
Equity Sentiment Index	Tính toán chỉ số sentiment theo ngày và tuần	Chỉ số equity sentiment được tính tự động theo ngày/tuần
Phân tích tác động	Phân tích mối quan hệ giữa sentiment và VN-Index/cổ phiếu	Báo cáo tương quan, hồi quy, abnormal return và hướng backtesting
Báo cáo tổng kết	Tổng hợp quy trình, kết quả và hướng mở rộng	Báo cáo cuối kỳ có thể dùng để trình bày lại toàn bộ pipeline

3.3 Phạm vi báo cáo

Báo cáo tập trung trả lời bốn câu hỏi chính:

1. Dữ liệu giá lịch sử và dữ liệu tin tức được làm sạch như thế nào?
2. Dictionary sentiment tài chính và sentiment score cho từng bài báo được xây dựng ra sao?
3. Equity Sentiment Index theo ngày, tuần và tháng được tính bằng công thức nào?
4. Chỉ số sentiment có quan hệ như thế nào với return và abnormal return của VN-Index?

CHƯƠNG 4

Tổng quan dữ liệu và cấu trúc pipeline

4.1 Kích thước dữ liệu sau các bước xử lý

Một số kết quả trung gian quan trọng:

File	Số dòng	Ghi chú
data_News/dataset_news.parquet	719.603	Dữ liệu tin tức ban đầu
data_News/clean_news.parquet	678.418	Tin tức sau làm sạch cơ bản
data_News/equity_news.parquet	130.545	Tin tức liên quan thị trường cổ phiếu
data_News/equity_news_clean_content.parquet	126.576	Nội dung bài báo sau làm sạch
data_News/equity_news_tokenized_vncorenlp.parquet	126.576	Nội dung đã tách từ
data_News/candidate_ngram_terms.parquet	43.840	Candidate terms sau lọc n-gram
data_News/candidate_ngram_terms_dictionary.parquet	43.840	Dictionary sentiment tài chính
data_News/equity_news_content_sentiment_ratios.parquet	126.576	Bài báo có sentiment score và label
data_News/market_sentiment_index_daily.parquet	5.037	Sentiment index theo ngày
data_News/market_sentiment_index_weekly.parquet	731	Sentiment index theo tuần
data_Histo/historical_price_all.parquet	4.307.791	Dữ liệu giá lịch sử
data_Histo/vnindex_weekly_return.parquet	793	Weekly return của VN-Index
data_News/vnindex_weekly_sentiment_merged.parquet	722	Dữ liệu weekly sau merge

Table 4.1: Kích thước dữ liệu sau các bước xử lý

- Note: có 9 tuần nghỉ lễ tết chưa được xử lý nên số quan sát sau merge là 722 thay vì 731.

Dữ liệu	Khoảng thời gian
Tin tức cổ phiếu sau làm sạch	01/01/2010 – 31/12/2023
Dữ liệu giá lịch sử	04/01/2010 – 12/05/2025
Daily sentiment index	01/01/2010 – 31/12/2023
Weekly sentiment/VN-Index merged	Theo tuần, giai đoạn 2010 – 2023

Table 4.2: Các mốc thời gian chính của dữ liệu

4.2 Luồng xử lý tổng quát

Luồng xử lý được triển khai theo thứ tự sau:

Nhánh xử lý	Luồng chính	Output
Giá lịch sử	Historical price raw -> kiểm tra OHLCV/duplicate/mã chứng khoán -> dữ liệu VN-Index sạch	Weekly VN-Index return
Tin tức	News raw -> clean metadata/domain/category -> lọc equity news -> clean content -> tách từ VNCORENLP	Nội dung tin tức sạch đã tách từ
Sentiment	Candidate n-gram terms -> financial sentiment dictionary -> sentiment score theo bài báo	Daily/weekly/monthly sentiment index
Tác động VN-Index	Weekly return + weekly sentiment -> merge theo tuần -> correlation/regression/abnormal return	Bộ kết quả phân tích tác động

CHƯƠNG 5

Xử lý dữ liệu giá lịch sử

5.1 Mục tiêu xử lý Historical_price

Phần Historical_price có nhiệm vụ chuẩn hóa dữ liệu giá lịch sử và tạo các biến thị trường dùng cho phân tích tác động. Dữ liệu giá là nền tảng để tính return của VN-Index, kiểm tra biến động giá, và ghép với sentiment index theo tuần.

Các mục tiêu chính gồm:

1. Đọc dữ liệu giá lịch sử từ file parquet.
2. Chuẩn hóa kiểu dữ liệu cho các cột như symbol, date, year, open, high, low, close, volume.
3. Lọc các mã chứng khoán nằm trong danh sách cần phân tích.
4. Kiểm tra lỗi dữ liệu như ngày không hợp lệ, sai năm, trùng symbol-date, giá âm hoặc bằng 0, quan hệ OHLC không hợp lệ.
5. Tạo dữ liệu riêng cho VN-Index.
6. Tạo return và các biến trễ để phục vụ phân tích tác động.

5.2 Kiểm tra chất lượng dữ liệu giá

Các nhóm kiểm tra chính gồm:

Nhóm kiểm tra	Mục đích
Chuẩn hóa mã	Đảm bảo symbol được đưa về dạng string, viết hoa, loại khoảng trắng
Chuẩn hóa ngày	Chuyển date về định dạng datetime
Kiểm tra năm	So sánh year trong dữ liệu với năm suy ra từ date
Kiểm tra trùng lặp	Phát hiện các dòng trùng cùng symbol và date
Kiểm tra OHLC	Loại các dòng có open/high/low/close không hợp lệ
Kiểm tra quan hệ giá	Đảm bảo $high \geq open$, $close$, low và $low \leq open$, $close$, $high$

Việc kiểm tra này quan trọng vì chỉ cần một số dòng lỗi trong chuỗi giá cũng có thể làm sai return, volatility và abnormal return. Với dữ liệu tài chính, các lỗi như giá bằng 0, ngày sai hoặc duplicate có thể tạo ra biến động giả, làm méo kết quả hồi quy.

5.3 Xử lý cột symbol

Vì trong cột symbol của dataset có các mã phái sinh nên không thể giữ lại vì đây không phải niêm yết của công ty khoảng (1536 ticker)

Sau khi lọc, dữ liệu được dùng cho các bước EDA, tạo feature và tách riêng VN-Index.

5.4 Làm sạch và tạo feature

1. Loại bỏ các dòng có giá OHLC bằng 0 hoặc không hợp lệ.
2. Chuẩn hóa những dòng có volume bằng 0 nhưng vẫn có giá giao dịch.
3. Tạo bộ dữ liệu sạch phục vụ EDA.

Tạo các biến đặc trưng cho dữ liệu giá, bao gồm:

Nhóm feature	Ví dụ	Ý nghĩa
Return lag	return_lag_1w	Return của tuần trước, dùng để kiểm soát quán tính thị trường
Volatility	volatility_12w	Độ lệch chuẩn return trong 12 tuần gần nhất, đại diện cho mức rủi ro/biến động
Target return	future_ret_1w, future_ret_4w	Return tương lai của VN-Index ở horizon 1 tuần và 4 tuần
Target abnormal return	future_abnormal_rolling_ret_1w, future_abnormal_rolling_ret_4w, future_abnormal_ar1_ret_1w, future_abnormal_ar1_ret_4w	Abnormal return tương lai theo rolling mean và AR(1)

Các feature này là nền tảng nếu mở rộng sang bài toán dự báo cổ phiếu hoặc backtesting tín hiệu giao dịch.

5.5 Tách dữ liệu VN-Index

Kết quả dữ liệu VN-Index sau xử lý gồm 3.826 quan sát, trải dài từ 04/01/2010 đến 12/05/2025. Dữ liệu này được dùng để tính return theo tuần, tạo biến trễ, volatility 12 tuần và các target future return.

- Dữ liệu của VnIndex đã được hiệu chỉnh nên giá trị `adj_ratio` đã được áp dụng vào giá `close`, do đó không cần hiệu chỉnh thêm. Tuy nhiên, nếu mở rộng sang các mã cổ phiếu khác, cần chú ý đến việc hiệu chỉnh giá để tránh sai lệch khi tính return.

Tạm bỏ qua biểu đồ VN-Index cumulative return
do chưa tìm thấy data_Histo/vnindex_eda_output.csv

Figure 5.1: VN-Index cumulative return giai đoạn 2010–2025

Biểu đồ trên sử dụng cumulative return thay vì chỉ vẽ `close_price`, vì trong phân tích tài chính return phản ánh trực tiếp mức tăng trưởng tích lũy của chỉ số theo thời gian.

CHƯƠNG 6

Xử lý dữ liệu tin tức

6.1 Mục tiêu xử lý News

Phần News có nhiệm vụ biến dữ liệu tin tức thô thành dữ liệu văn bản có thể dùng cho NLP và sentiment analysis. Với dữ liệu tiếng Việt, bước này đặc biệt quan trọng vì nội dung thô thường chứa lỗi crawl, đoạn liên quan, mô tả lặp lại, tiêu đề bị lặp trong content, hoặc các bài không liên quan trực tiếp đến thị trường cổ phiếu.

Các bước chính gồm:

1. EDA dữ liệu tin tức thô.
2. Làm sạch metadata như ngày đăng, domain, category, keyword.
3. Lọc tin tức liên quan đến thị trường cổ phiếu.
4. Làm sạch nội dung bài viết.
5. Tách từ tiếng Việt bằng VNCoreNLP.
6. Trích xuất candidate terms bằng n-gram.
7. Xây dựng dictionary sentiment tài chính.
8. Gán sentiment score và label cho từng bài báo.

6.2 EDA dữ liệu tin tức thô

Nhóm EDA	Nội dung
Missing value	Kiểm tra số lượng giá trị thiếu theo cột
Ngày đăng	Parse <code>publication_date</code> , kiểm tra khoảng thời gian
Nội dung văn bản	Tính số từ title, description, content
Trùng lặp	Kiểm tra duplicate theo link và ngày
Domain/category	Thống kê nguồn tin và nhóm tin
Keyword	Chuẩn hóa và kiểm tra keyword

Dữ liệu tin tức ban đầu có 719.603 records. Sau bước làm sạch cơ bản còn 678.418 records.

6.3 Làm sạch metadata

File `News/EDA_clean/news_clean.py` tạo dữ liệu `clean_news.parquet`. Các xử lý chính gồm:

1. Chuẩn hóa domain về `domain_norm`.
 - bỏ `http://`, `https://`, `www.`, bỏ path sau `/`, bỏ query sau `?`, bỏ fragment sau `#` và chỉ giữ phần tên miền chính.
2. Parse ngày đăng và loại bỏ dòng có ngày không hợp lệ.
 - 79 dòng bị loại vì ngày đăng không parse được do lỗi format dạng `00:00:0000`
3. Loại các bài trước năm 2010 để đồng bộ với dữ liệu giá lịch sử.
 - 22.316 dòng bị loại.
4. Chuẩn hóa keyword từ dạng chuỗi/dict-like về dạng để xử lý.
5. Tính độ dài description và loại các bài có mô tả quá ngắn.
 - 18.790 dòng bị loại vì description có độ dài dưới 5 từ, vì những bài này thường không đủ thông tin để phân tích sentiment.
6. Loại duplicate theo link và ngày đăng.
7. Giữ các cột chính: `publication_date`, `year`, `domain_norm`, `category`, `title`, `description`, `keywords_norm`.

Mục tiêu của bước này là tạo một lớp dữ liệu tin tức sạch về mặt metadata trước khi xử lý nội dung sâu hơn.

6.4 Lọc tin tức cổ phiếu

Sau khi lọc theo category chỉ giữ lại những category liên quan đến equity, dữ liệu còn 130.545 records. Đây là tập tin tức tập trung vào bối cảnh thị trường cổ phiếu Việt Nam, tránh đưa quá nhiều tin vĩ mô, xã hội hoặc tin không liên quan vào sentiment index.

6.5 Làm sạch nội dung bài báo

Bước này xử lý các vấn đề thường gặp trong dữ liệu crawl:

Vấn đề	Cách xử lý
Tiêu đề/mô tả lặp trong content	Loại bỏ phần trùng với title hoặc description
Đoạn gợi ý bài liên quan	Cắt theo các marker như “Có thể bạn quan tâm”
Nội dung quá ngắn	Thay bằng description nếu description đủ thông tin

Vấn đề	Cách xử lý
Nhiều theo nguồn cụ thể	Có logic riêng cho một số domain/case đặc biệt
Khoảng trắng và ký tự thừa	Chuẩn hóa khoảng trắng

- Lọc theo domain loại 40 records
- Xóa 3.969 content chứa phrase nhiễu

-> Sau bước này, dữ liệu còn 126.576 bài báo, là tập nội dung chính dùng cho tách từ, sentiment scoring và fine-tune model.

6.6 Tách từ tiếng Việt (Tokenize Vietnamese text)

File `News/prepare_data_model/used_for_v1/tokenize_VNCoreNLP.py` dùng VNCoreNLP để tách từ và tách câu cho nội dung tiếng Việt. Đây là bước cần thiết vì tiếng Việt là ngôn ngữ đơn lập, nhiều khái niệm tài chính là cụm nhiều âm tiết như lợi nhuận, thanh khoản, tăng trưởng, áp lực bán, dòng tiền.

Nếu không tách từ, mô hình n-gram và PhoBERT có thể hiểu sai ranh giới từ. Ví dụ:

Văn bản gốc	Sau tách từ
lợi nhuận tăng mạnh	lợi_nhuận tăng mạnh
áp lực bán gia tăng	áp_lực_bán gia_tăng
dòng tiền tích cực	dòng_tiền tích_cực

Kết quả được lưu ở `data_News/equity_news_tokenized_vncorenlp.parquet`.

CHƯƠNG 7

Trích xuất candidate terms và xây dựng dictionary sentiment

7.1 Trích xuất candidate n-gram

Sau khi có nội dung đã tách từ, pipeline xây dựng tập candidate terms bằng n-gram. Mục tiêu là tìm các từ/cụm từ có khả năng mang ý nghĩa sentiment trong tài chính.

File `News/prepare_data_model/build_CSR_matrix.py` và các script liên quan tạo ma trận term-document bằng `CountVectorizer`. Từ đó, pipeline tính các chỉ số:

Chỉ số	Ý nghĩa
tf	Tổng số lần term xuất hiện trong toàn bộ corpus
df	Số bài báo có chứa term
df_ratio	Tỷ lệ bài báo có chứa term
ngram_size	Độ dài của term: unigram, bigram

Tổng số n-gram được tạo ra là **2.858.165**, bao gồm:

- Uni-gram: 141.397
- Bi-gram: 2.716.768

File `candidate_term_ngram.py` lọc candidate terms theo các điều kiện như:

1. Loại những tokenize chứa stopwords ở đầu hoặc cuối (1.425.053)
2. Loại term quá phổ biến (xuất hiện trong hơn 22% bài báo) (40)
3. Loại quá hiếm
 - min_df unigram = 5000 (140.231)
 - min_df bigram = 200 (1.248.986)
4. Ưu tiên các cụm sentiment có ý nghĩa trong tài chính.
 - Ví dụ (tăng_trưởng, giảm_mạnh, lợi_nhuận_tăng,...)
5. Xử lý trường hợp bigram/unigram để tránh nhiều khi cần.

-> Tập candidate cuối cùng có 43.840 terms.

7.2 Xây dựng dictionary sentiment tài chính

File `News/Process_sentiment_label/build_sentiment_dictionary.py` dùng model `wonrax/phobert-base-vietnamese-sentiment` để gán sentiment cho từng candidate

term. Đầu ra là file:

`data_News/candidate_ngram_terms_dictionary.parquet`

Dictionary gồm 43.840 terms, với phân bố như:

Sentiment label	Số lượng term
Positive	16.485
Negative	9.699
Neutral	17.656

Dictionary này đóng vai trò là lớp tri thức tài chính ban đầu. Thay vì chỉ dùng model tổng quát để đọc cả bài báo, dictionary giúp đo sentiment theo term trong ngữ cảnh tài chính, từ đó tạo nhãn yếu cho content và xây dựng sentiment score.

7.3 Lý do cần dictionary theo ngữ cảnh tài chính

Một số từ trong tiếng Việt có thể mang ý nghĩa khác nhau tùy ngữ cảnh. Ví dụ, “giảm” trong ngữ cảnh chi phí có thể là tích cực, nhưng “giảm lợi nhuận” lại tiêu cực. Tương tự, “tăng” không phải lúc nào cũng tích cực nếu đi cùng các cụm như “tăng lỗ”, “tăng áp lực bán”, “tăng nợ”.

Vì vậy, dictionary tài chính cần ưu tiên cụm từ thay vì chỉ xét từng từ đơn. Cụm `lợi_nhuận tăng`, `áp_lực_bán`, `dòng_tiền tích_cực` thường mang thông tin rõ hơn so với các unigram như `tăng`, `giảm`, `áp_lực`.

CHƯƠNG 8

Gán sentiment score cho bài báo (basic solution)

8.1 Input và output

File `News/Process_sentiment_label/build_sentiment_label_content.py` đọc hai nguồn dữ liệu:

1. `data_News/candidate_ngram_terms_dictionary.parquet`: dictionary sentiment theo term.
2. `data_News/equity_news_tokenized_vncorenlp.parquet`: nội dung bài báo đã tách từ.

Đầu ra là:

`data_News/equity_news_content_sentiment_ratios.parquet`

File này chứa các cột sentiment cho từng bài báo, ví dụ:

Nhóm cột	Ý nghĩa
<code>positive_count</code>	Số lần match term positive
<code>negative_count</code>	Số lần match term negative
<code>neutral_count</code>	Số lần match term neutral
<code>positive_ratio</code>	Tỷ lệ positive trên tổng token
<code>negative_ratio</code>	Tỷ lệ negative trên tổng token
<code>neutral_ratio</code>	Tỷ lệ neutral trên tổng token
<code>sentiment_score</code>	Điểm sentiment tổng hợp
<code>sentiment_label</code>	Nhãn positive/negative/neutral của bài báo

8.2 Công thức sentiment score (fundamental formula)

Sau khi đếm số term positive và negative trong bài báo, sentiment score được tính theo công thức:

$$sentiment_score = \frac{positive_count - negative_count}{positive_count + negative_count}$$

Trong đó:

- `positive_count` là số term tích cực match được trong bài báo.

- `negative_count` là số term tiêu cực match được trong bài báo.
- Mẫu số chỉ tính positive và negative để đo độ lệch cảm xúc thực sự.
- Neutral được dùng như thông tin bổ sung về độ bao phủ từ điển, không trực tiếp kéo điểm về 0.

Giá trị `sentiment_score` nằm trong khoảng từ -1 đến 1:

Giá trị	Diễn giải
Gần 1	Bài báo nghiêng mạnh về positive
Gần 0	Bài báo cân bằng hoặc không rõ sentiment
Gần -1	Bài báo nghiêng mạnh về negative

8.3 Quy tắc gán nhãn content

Trong pipeline hiện tại, nhãn bài báo được gán theo hướng thận trọng bằng cách kết hợp `sentiment_score` với `polarity_count`.

Biến `polarity_count` được tính bằng:

$$polarity_count = positive_count + negative_count$$

Biến này chỉ đếm các token có cực tính rõ ràng là positive hoặc negative, không cộng `neutral_count`. Lý do là neutral term giúp đo mức độ bao phủ của dictionary, nhưng không nên quyết định chiều cảm xúc của bài báo.

Điều kiện	Nhãn
<code>polarity_count < 2</code>	Neutral
<code>polarity_count >= 2</code> và <code>sentiment_score >= 0,30</code>	Positive
<code>polarity_count >= 2</code> và <code>sentiment_score <= -0,30</code>	Negative
Còn lại	Neutral

Cách này giúp hạn chế việc một bài báo bị gán positive hoặc negative chỉ vì xuất hiện một từ đơn lẻ. Nếu `polarity_count` nhỏ hơn 2, bài báo được gán neutral dù `sentiment_score` có thể lệch về một phía, vì số lượng tín hiệu cảm xúc chưa đủ tin cậy. Với dữ liệu tài chính, nhiều bài báo có nội dung thông tin trung tính, nên việc giữ lớp neutral là cần thiết.

Thống kê theo `polarity_count`:

Nhóm bài báo	Số bài báo
<code>polarity_count < 2</code>	17.907
<code>polarity_count >= 2</code>	108.669
Đủ <code>polarity</code> và <code>sentiment_score >= 0,30</code>	72.849
Đủ <code>polarity</code> và <code>sentiment_score <= -0,30</code>	11.676

Kết quả gán nhãn trên 126.576 bài báo:

Sentiment label	Số bài báo
Positive	72.849
Negative	11.676
Neutral	42.051

Phân bố nhãn cho thấy lớp positive chiếm tỷ trọng lớn nhất trong tập dữ liệu. Cụ thể, positive có 72.849 bài, tương đương khoảng 57,6% tổng số bài; neutral có 42.051 bài, tương đương khoảng 33,2%; negative chỉ có 11.676 bài, tương đương khoảng 9,2%. Đây là một điểm cần lưu ý khi sử dụng tập nhãn này để fine-tune mô hình PhoBERT.

Sự mất cân bằng nhãn có thể ảnh hưởng đến mô hình theo một số cách:

Vấn đề	Ảnh hưởng tới mô hình
Positive chiếm tỷ trọng lớn	Model có xu hướng dự đoán positive nhiều hơn
Negative ít hơn rõ rệt	Recall của lớp negative có thể thấp hơn positive
Accuracy dễ bị lạc quan	Model đoán tốt lớp positive đã có thể đạt accuracy tương đối cao
Macro F1 quan trọng hơn accuracy	Macro F1 phản ánh công bằng hơn giữa positive, negative và neutral

Vì vậy, khi đánh giá mô hình sentiment, không nên chỉ nhìn accuracy. Cần xem thêm precision, recall và F1-score theo từng lớp. Trong kết quả kiểm thử, lớp negative có F1-score thấp hơn positive, phản ánh đúng rủi ro từ việc số lượng mẫu negative ít hơn. Nếu tiếp tục cải thiện mô hình, có thể áp dụng một số hướng như cân bằng lại dữ liệu train, dùng class weight, oversampling lớp negative, hoặc kiểm tra thủ công thêm các bài negative để tăng chất lượng nhãn.

CHƯƠNG 9

Fine-tune mô hình PhoBERT cho sentiment tài chính (1st version)

9.1 Mục tiêu fine-tune

Model `wonrax/phobert-base-vietnamese-sentiment` là mô hình sentiment tiếng Việt tổng quát. Tuy nhiên, bài toán của đề tài là sentiment trong ngữ cảnh tài chính. Vì vậy, mô hình cần được fine-tune lại trên tập content đã được gán nhãn bằng dictionary tài chính.

Mục tiêu của fine-tune là:

1. Giúp model học cách phân biệt positive, negative, neutral trong tin tức chứng khoán.
2. Giảm phụ thuộc hoàn toàn vào rule-based dictionary.
3. Tạo mô hình có thể nhận đầu vào là nội dung bài báo mới và dự đoán sentiment trực tiếp.
4. Kiểm tra xem tập nhãn được xây dựng có đủ nhất quán để huấn luyện model hay không.

9.2 Input của mô hình

Input của PhoBERT là văn bản tiếng Việt đã được làm sạch và tách từ. Trong pipeline, cột chính là `Tokenize_content`.

Ví dụ:

Content gốc	Input cho PhoBERT
Thị trường chứng khoán tăng điểm nhờ dòng tiền tích cực	Thị_trường_chứng_khoán_tăng_điểm_nhờ_dòng_tiền_tích_cực

Mỗi bài báo được map với một nhãn:

Nhãn	Ý nghĩa
positive	Tin tức có sentiment tích cực
negative	Tin tức có sentiment tiêu cực
neutral	Tin tức trung tính hoặc không rõ chiều

9.3 Train/test split

File train model chia dữ liệu thành train/test theo tỷ lệ 80/20, có stratify theo nhãn. Việc stratify giúp phân phối positive, negative và neutral trong tập train/test gần giống nhau, tránh trường hợp tập test bị lệch nhãn.

Quy trình huấn luyện:

Bước	Nội dung
1	Đọc equity_news_content_sentiment_ratios
2	Làm sạch text và map nhãn sentiment
3	Chia train/test theo tỷ lệ 80/20, stratify theo label
4	Tokenize bằng PhoBERT tokenizer
5	Fine-tune mô hình sequence classification
6	Evaluate bằng accuracy, macro F1, weighted F1
7	Lưu fine-tuned model để tái sử dụng

9.4 Kết quả đánh giá mô hình

Trong lần kiểm thử đã chạy, mô hình đạt:

Metric	Giá trị
Accuracy	0,855
Macro F1	0,820
Weighted F1	0,854

Classification report:

Label	Precision	Recall	F1-score	Support
Negative	0,80	0,74	0,77	2.335
Positive	0,89	0,92	0,91	14.570
Neutral	0,80	0,76	0,78	8.411
Accuracy			0,85	25.316
Macro avg	0,83	0,81	0,82	25.316
Weighted avg	0,85	0,85	0,85	25.316

Kết quả này đạt mục tiêu accuracy từ 80%. Tuy nhiên, cần lưu ý rằng nhãn train được tạo từ dictionary/rule-based pipeline, nên đây là đánh giá trên nhãn yếu chứ chưa phải nhãn thủ

công hoàn toàn. Vì vậy, kết quả cần được hiểu là mô hình học tốt quy tắc sentiment tài chính hiện tại, chưa đủ để khẳng định mô hình đạt chất lượng tương đương một bộ nhân chuyên gia.

CHƯƠNG 10

Xây dựng Equity Sentiment Index (rule-based approach)

10.1 Ý tưởng

Sau khi mỗi bài báo có `sentiment_score` và `sentiment_label`, bước tiếp theo là tổng hợp sentiment theo thời gian để tạo Equity Sentiment Index. Đây là chỉ số phản ánh mức độ tích cực/tiêu cực trung bình của tin tức tài chính trong một ngày, một tuần hoặc một tháng.

Về trực giác:

- Nếu nhiều bài báo trong cùng kỳ có sentiment positive, chỉ số tăng.
- Nếu nhiều bài báo tiêu cực, chỉ số giảm.
- Nếu tin tức chủ yếu trung tính, chỉ số ở gần mức trung bình.

10.2 Daily sentiment index

File `News/Build_sentiment_index/build_sentiment_index_daily.py` tính sentiment index theo ngày. Với mỗi ngày, pipeline tính:

Cột	Ý nghĩa
<code>date</code>	Ngày giao dịch/tin tức
<code>article_count</code>	Số bài báo trong ngày
<code>sentiment_index</code>	Trung bình <code>sentiment_score</code> của các bài trong ngày
<code>sentiment_index_z</code>	Z-score của sentiment index
<code>positive_article_count</code>	Số bài positive
<code>negative_article_count</code>	Số bài negative
<code>neutral_article_count</code>	Số bài neutral

Công thức sentiment index ngày:

$$SI_t = \frac{1}{N_t} \sum_{i=1}^{N_t} score_{i,t}$$

Trong đó:

- SI_t là sentiment index tại ngày t .

- N_t là số bài báo trong ngày t .
- $score_{i,t}$ là sentiment score của bài báo i trong ngày t .

Kết quả daily index có 5.037 dòng.

10.3 Weekly sentiment index

File `News/Build_sentiment_index/build_sentiment_index_weekly.py` gom dữ liệu theo tuần bằng W-SUN, tức tuần bắt đầu từ thứ Hai và kết thúc vào Chủ nhật.

Các cột chính:

Cột	Ý nghĩa
<code>week_start</code>	Ngày bắt đầu tuần
<code>week_end</code>	Ngày kết thúc tuần
<code>article_count</code>	Số bài báo trong tuần
<code>sentiment_index</code>	Trung bình sentiment score trong tuần
<code>sentiment_index_z</code>	Z-score theo toàn bộ chuỗi tuần
<code>positive_article_count</code>	Số bài positive trong tuần
<code>negative_article_count</code>	Số bài negative trong tuần
<code>neutral_article_count</code>	Số bài neutral trong tuần

Việc gom tuần từ thứ Hai đến Chủ nhật phù hợp với dữ liệu tin tức vì tin có thể xuất hiện cả cuối tuần. Khi merge với VN-Index, tuần được căn theo `week_end` để đảm bảo sentiment của cùng một tuần được ghép với return của cùng kỳ hoặc dùng để tạo biến dự báo tuần sau.

Kết quả weekly index có 731 dòng.

10.4 Monthly sentiment index

File `News/Build_sentiment_index/build_sentiment_index_monthly.py` mở rộng cách tính sang cấp tháng. Monthly index phù hợp khi cần phân tích xu hướng sentiment dài hơn, giảm nhiễu ngày/tuần và so sánh với biến tài chính/vĩ mô có tần suất thấp.

Các cột chính gồm:

Cột	Ý nghĩa
<code>month</code>	Tháng quan sát
<code>month_start</code>	Ngày đầu tháng
<code>month_end</code>	Ngày cuối tháng
<code>article_count</code>	Số bài trong tháng

Cột	Ý nghĩa
sentiment_index	Trung bình sentiment score trong tháng
sentiment_index_z	Z-score theo chuỗi tháng

10.5 Chuẩn hóa z-score

Z-score được tính theo công thức:

$$SI_t^z = \frac{SI_t - \mu(SI)}{\sigma(SI)}$$

Trong đó:

- $\mu(SI)$ là trung bình sentiment index toàn kỳ.
- $\sigma(SI)$ là độ lệch chuẩn sentiment index toàn kỳ.

Lợi ích của chuẩn hóa z-score:

1. Đưa sentiment index về cùng thang đo, dễ so sánh giữa ngày, tuần và tháng.
2. Diễn giải được mức độ bất thường: z-score = 2 nghĩa là sentiment cao hơn trung bình 2 độ lệch chuẩn.
3. Giúp hồi quy ổn định hơn vì biến sentiment không phụ thuộc vào scale ban đầu.
4. Cho phép so sánh sentiment với các biến khác như return, volatility, article count.

Z-score không làm thay đổi thứ tự tăng/giảm của sentiment index, mà chỉ chuẩn hóa mức độ lệch khỏi trạng thái bình thường.

CHƯƠNG 11

Xử lý VN-Index và phân tích tác động

Trong phần phân tích tác động đến VN-Index, em lựa chọn tần suất tuần (weekly) làm đơn vị phân tích chính. Lý do là dữ liệu tin tức có thể xuất hiện cả trong ngày nghỉ, cuối tuần hoặc các giai đoạn thị trường không giao dịch, trong khi dữ liệu giá VN-Index chỉ phản ánh các ngày giao dịch. Việc gom theo tuần giúp đồng bộ hai nguồn dữ liệu, giảm nhiều ngắn hạn theo ngày và phù hợp hơn với mục tiêu kiểm tra tác động của sentiment đến xu hướng thị trường trong ngắn hạn.

Ngoài ra, do thời gian thực tập có hạn, phạm vi kiểm thử định lượng được ưu tiên triển khai trước ở mức weekly. Các phân tích ở tần suất daily hoặc monthly có thể được mở rộng trong các bước nghiên cứu tiếp theo để so sánh độ ổn định của kết quả và kiểm tra xem tác động sentiment có thay đổi theo từng khung thời gian hay không.

11.1 Tạo weekly return cho VN-Index

File `News_Vnindex/build_vnindex_weekly_return.py` đọc dữ liệu VN-Index từ:
`data_Histo/vnindex_eda_output.csv`

Sau đó gom theo tuần W-SUN. Với mỗi tuần, pipeline lấy:

Cột	Cách tính
<code>week_start</code>	Ngày bắt đầu tuần
<code>week_end</code>	Ngày kết thúc tuần
<code>first_trading_date</code>	Ngày giao dịch đầu tiên trong tuần
<code>last_trading_date</code>	Ngày giao dịch cuối cùng trong tuần
<code>open</code>	Giá mở cửa đầu tuần
<code>close</code>	Giá đóng cửa cuối tuần
<code>high</code>	Giá cao nhất trong tuần
<code>low</code>	Giá thấp nhất trong tuần
<code>volume</code>	Tổng volume trong tuần
<code>trading_day_count</code>	Số ngày giao dịch trong tuần

Weekly return được tính:

$$return_t = \ln \left(\frac{close_t}{close_{t-1}} \right)$$

Trong đó $close_t$ là giá đóng cửa cuối tuần hiện tại, $close_{t-1}$ là giá đóng cửa cuối tuần trước. Đây là log return, phù hợp để cộng dồn return qua nhiều kỳ và thường được dùng trong phân tích chuỗi thời gian tài chính.

File đầu ra:

`data_Histo/vnindex_weekly_return.parquet`

11.2 Tạo biến future return

Để phân tích tác động dự báo, pipeline tạo các biến tương lai:

Biến	Ý nghĩa
<code>future_ret_1w</code>	Log return của tuần kế tiếp
<code>future_ret_4w</code>	Log return tích lũy của 4 tuần tiếp theo
<code>return_lag_1w</code>	Return của tuần trước
<code>volatility_12w</code>	Độ lệch chuẩn return trong 12 tuần gần nhất
<code>log_vol_total</code>	Log của tổng giá trị/khối lượng giao dịch

Trong đó:

$$future_ret_1w_t = \ln \left(\frac{close_{t+1}}{close_t} \right)$$

và:

$$future_ret_4w_t = \ln \left(\frac{close_{t+4}}{close_t} \right)$$

Do đó, sentiment của tuần t được dùng để phân tích log return tương lai, đặc biệt là tuần kế tiếp và bốn tuần kế tiếp.

Sau đó News này sẽ được merge với VN-Index theo start-week và week-end

CHƯƠNG 12

Abnormal return

12.1 Lý do dùng abnormal return

Return thông thường cho biết VN-Index tăng hay giảm. Tuy nhiên, để phân tích tác động của sentiment, chỉ nhìn return thô có thể chưa đủ, vì return còn chịu ảnh hưởng từ xu hướng thị trường, quán tính giá và các yếu tố nền.

Abnormal return được dùng để đo phần return vượt ngoài mức kỳ vọng:

$$abnormal_return_t = actual_return_t - expected_return_t$$

Trong đó:

- `actual_return` là return thực tế.
- `expected_return` là return kỳ vọng theo một mô hình nền.
- `abnormal_return` là phần bất thường còn lại.

Nếu sentiment có quan hệ với abnormal return, điều đó gợi ý rằng sentiment có thể giải thích phần biến động không chỉ đến từ xu hướng thông thường của thị trường.

12.2 Hai cách tính expected return

File `News_Vnindex/build_vnindex_weekly_abnormal_return.py` tạo abnormal return theo hai cách.

12.2.1 Cách 1: Rolling mean expected return

Expected return được tính bằng trung bình return của 26 tuần trước đó:

$$E(r_t) = \frac{1}{26} \sum_{k=1}^{26} r_{t-k}$$

Sau đó:

$$abnormal_return_t^{rolling} = r_t - E(r_t)$$

Cách này đơn giản, dễ hiểu và ổn định. Nó giả định return kỳ vọng của tuần hiện tại gần

với trung bình trong nửa năm trước đó.

12.2.2 Cách 2: Rolling AR(1)

Mô hình AR(1) giả định return tuần này có quan hệ tuyến tính với return tuần trước:

$$r_t = \alpha + \beta r_{t-1} + \epsilon_t$$

Với mỗi tuần, pipeline dùng cửa sổ 52 tuần trước đó để ước lượng α và β , sau đó dự báo expected return cho tuần hiện tại:

$$E(r_t) = \hat{\alpha} + \hat{\beta} r_{t-1}$$

Abnormal return:

$$abnormal_return_t^{AR1} = r_t - E(r_t)$$

Cách này linh hoạt hơn rolling mean vì nó cho phép return có quán tính theo tuần trước. Tuy nhiên, nó cũng nhạy hơn với kích thước cửa sổ và chất lượng dữ liệu.

12.3 Future abnormal return

Sau khi có abnormal return từng tuần, pipeline tạo target tương lai:

Biến	Ý nghĩa
future_abnormal_rolling_ret_1w	Abnormal return rolling của tuần kế tiếp
future_abnormal_rolling_ret_4w	Tổng abnormal return rolling của 4 tuần kế tiếp
future_abnormal_ar1_ret_1w	Abnormal return AR(1) của tuần kế tiếp
future_abnormal_ar1_ret_4w	Tổng abnormal return AR(1) của 4 tuần kế tiếp

Các biến này giúp kiểm tra liệu sentiment hiện tại có liên quan tới phần return bất thường trong tương lai hay không.

CHƯƠNG 13

Predictive regression

13.1 Mục tiêu

Để kiểm tra tác động của sentiment trong khi kiểm soát một số biến thị trường khác, pipeline sử dụng predictive regression.

Mô hình tổng quát:

$$Y_{t+h} = \alpha + \beta_1 \text{Sentiment}_t + \beta_2 \text{ReturnLag}_t + \beta_3 \text{Volatility}_t + \beta_4 \text{LogArticleCount}_t + \epsilon_t$$

Trong đó:

Thành phần	Ý nghĩa
Y_{t+h}	Return hoặc abnormal return tương lai
Sentiment_t	sentiment_index_z của tuần hiện tại
ReturnLag_t	Return tuần trước
Volatility_t	Volatility 12 tuần
LogArticleCount_t	Log số lượng bài báo
α	Hệ số chặn
ϵ_t	Sai số mô hình

13.2 Target và predictor

Các target được chạy hồi quy:

Target	Ý nghĩa
future_ret_1w	Return tuần kế tiếp
future_ret_4w	Tổng return 4 tuần kế tiếp
future_abnormal_rolling_ret_1w	Abnormal return rolling tuần kế tiếp
future_abnormal_rolling_ret_4w	Abnormal return rolling 4 tuần kế tiếp
future_abnormal_ar1_ret_1w	Abnormal return AR(1) tuần kế tiếp
future_abnormal_ar1_ret_4w	Abnormal return AR(1) 4 tuần kế tiếp

Các predictor:

Predictor	Vai trò
sentiment_index_z	Biến sentiment chính
return_lag_1w	Kiểm soát quán tính return
volatility_12w	Kiểm soát mức rủi ro/biến động
log_article_count	Kiểm soát cường độ tin tức

13.3 Newey-West standard error

Vì dữ liệu tài chính theo thời gian có thể có tự tương quan và phương sai thay đổi, pipeline sử dụng Newey-West standard error. Cách này giúp thống kê t và p-value thận trọng hơn so với standard error OLS thông thường.

Với target 1 tuần, `hac_lags = 1`. Với target 4 tuần, `hac_lags = 4`.

13.4 Kết quả hồi quy chính

Kết quả cho biến `sentiment_index_z`:

Table 13.1: Kết quả hồi quy cho biến `sentiment_index_z`

Target	Coefficient	t-stat	p-value	R ²	Số quan sát	Diễn giải
future_ret_1w	-0,0010	-0,939	0,348	0,0025	710	Không có ý nghĩa thống kê
future_ret_4w	-0,0109	-3,293	0,001	0,0373	710	Có ý nghĩa thống kê, tác động âm
future_abnormal_rolling_ret_1w	-0,0009	–	0,415	0,0066	709	Không có ý nghĩa thống kê
future_abnormal_rolling_ret_4w	-0,0105	–	0,0029	0,0416	706	Có ý nghĩa thống kê, tác động âm
future_abnormal_ar1_ret_1w	-0,0004	–	0,727	0,0037	694	Không có ý nghĩa thống kê
future_abnormal_ar1_ret_4w	-0,0076	–	0,0193	0,0211	691	Có ý nghĩa thống kê, tác động âm

Kết quả có thể diễn giải như sau:

- Ở horizon 1 tuần, sentiment chưa cho thấy tác động rõ ràng tới return hoặc abnormal return.
- Ở horizon 4 tuần, sentiment có hệ số âm và có ý nghĩa thống kê trong một vài target.
- R² nhìn chung thấp, cho thấy mô hình chỉ giải thích một phần nhỏ biến động VN-Index. Chưa thể khẳng định chắc chắn rằng liệu `news_sentiment` có thể ảnh hưởng đến `Vnindex` hay không trong lần kiểm thử này. (1st version)

-> Cần được kiểm chứng thêm bằng event study, rolling regression, High-Low sentiment phân tích theo giai đoạn thị trường và backtesting.

CHƯƠNG 14

Đánh giá pipeline hiện tại

14.1 Điểm mạnh

Pipeline hiện tại có một số điểm mạnh:

1. Đi từ dữ liệu thô đến chỉ số sentiment hoàn chỉnh, không chỉ dừng ở mô hình NLP.
2. Có xử lý riêng cho tiếng Việt thông qua VNCoreNLP và PhoBERT.
3. Có dictionary tài chính thay vì dùng sentiment phổ thông.
4. Có kiểm chứng mô hình với train/test split.
5. Có phân tích tác động bằng nhiều cách: correlation, abnormal return và predictive regression.
6. Có các output trung gian rõ ràng, giúp kiểm tra từng bước.

14.2 Hạn chế

Một số hạn chế cần ghi nhận:

1. Nhãn sentiment của content được tạo từ dictionary và rule-based score, chưa phải nhãn thủ công hoàn toàn.
2. Model PhoBERT fine-tuned học từ nhãn yếu, nên kết quả accuracy phản ánh mức độ học lại pipeline gán nhãn nhiều hơn là chất lượng nhãn chuyên gia.
3. Dictionary sentiment có thể còn nhầm ở các cụm từ phụ thuộc ngữ cảnh, ví dụ tăng_chi_phí và tăng_lợi_nhuận.
4. Sentiment index đang dùng trung bình score, chưa weighting theo độ quan trọng của nguồn tin, số lượt đọc hoặc mức độ liên quan đến VN-Index.
5. Phân tích tác động mới tập trung ở cấp VN-Index weekly, chưa mở rộng sâu sang từng cổ phiếu.
6. Kết quả hồi quy có R^2 thấp, cần thêm biến kiểm soát và kiểm định độ ổn định.

14.3 Rủi ro sai lệch dữ liệu

Một số nguồn sai lệch có thể ảnh hưởng kết quả:

Nguồn sai lệch	Ảnh hưởng
Tin tức crawl không đầy đủ	Làm sentiment index thiếu đại diện

Nguồn sai lệch	Ảnh hưởng
Domain/category filter	Có thể bỏ sót hoặc giữ nhầm tin
Nội dung trùng lặp	Làm một thông tin bị đếm nhiều lần
Dictionary tự động	Có thể gán sai sentiment cho term
Tin cuối tuần	Cần căn đúng tuần khi merge với dữ liệu giao dịch
Weak label cho content	Gây nhầm lẫn trong việc chạy model và hồi quy
Return target	Cách định nghĩa future return ảnh hưởng kết quả hồi quy

CHƯƠNG 15

Hướng phát triển

(Chưa hoàn thành)

15.1 Cải thiện dictionary sentiment

Một hướng quan trọng là kiểm tra thủ công một phần dictionary, đặc biệt là các term có tần suất cao hoặc confidence thấp. Có thể chia dictionary thành ba nhóm:

1. Term chắc chắn: giữ nguyên.
2. Term cần kiểm tra: review thủ công.
3. Term phụ thuộc ngữ cảnh: xử lý bằng cụm dài hơn hoặc model contextual.

Ngoài ra, có thể thêm trọng số cho term:

Trọng số	Ý nghĩa
Theo confidence của model	Term có confidence cao được tính mạnh hơn
Theo df/tf	Term phổ biến vừa phải được ưu tiên
Theo loại n-gram	Bigram/trigram có thể đáng tin hơn unigram
Theo domain tài chính	Term trong nguồn tin uy tín có thể được kiểm tra ưu tiên

- Có thể thêm các bước kiểm tra cho những term có chiếm đa số về label, thêm phương pháp **tf.idf** để xây dựng financial dictionary chính xác hơn làm giảm trọng số của các từ không cần thiết và tăng trọng số của các từ quan trọng,

15.2 Cải thiện sentiment score cho content

Sentiment score hiện tại dựa trên số lượng term positive/negative. Có thể mở rộng:

1. Dùng weighted score theo confidence.
2. Tách sentiment theo câu thay vì toàn bài.
3. Ưu tiên các câu gần tên doanh nghiệp, VN-Index hoặc từ khóa thị trường.
4. Giảm trọng số của các đoạn mô tả chung.
5. Kết hợp output của dictionary với output của PhoBERT fine-tuned.

15.3 Cải thiện Equity Sentiment Index

Một số hướng nâng cấp chỉ số:

1. Weight bài báo theo nguồn tin.
2. Weight theo độ dài hoặc mức độ liên quan đến cổ phiếu.
3. Loại bớt duplicate giữa các nguồn đưa lại cùng một thông tin.
4. Tạo index riêng cho từng nhóm ngành.
5. Tạo index riêng cho từng mã cổ phiếu nếu có mapping ticker-news tốt.
6. So sánh daily, weekly, monthly để chọn horizon phù hợp.

15.4 Mở rộng phân tích tác động

Với dữ liệu hiện tại, có thể mở rộng theo các hướng:

Phương pháp	Mục tiêu
Rolling regression	Kiểm tra tác động sentiment có thay đổi theo thời gian không
Event study	Đo phản ứng thị trường quanh ngày sentiment cực đoan
High-Low sentiment	So sánh return khi sentiment rất cao vs rất thấp
Regime analysis	Tách giai đoạn bull/bear/sideway
Quantile regression	Kiểm tra sentiment ảnh hưởng mạnh hơn ở đuôi phân phối không
Granger causality	Kiểm tra sentiment có giúp dự báo return ngoài return quá khứ không
Correlation analysis	Kiểm tra mối quan hệ giữa sentiment và các biến tài chính khác
Backtesting	Kiểm tra giá trị thực chiến của tín hiệu sentiment

15.5 Backtesting tín hiệu giao dịch (chưa hoàn thành)

Backtesting là bước tiếp theo để kiểm tra liệu sentiment index có thể tạo giá trị đầu tư hay không. Một ví dụ đơn giản:

Điều kiện	Hành động
sentiment_index_z rất thấp	Có thể xem là tín hiệu thị trường bị quan quá mức
sentiment_index_z rất cao	Có thể cảnh báo hưng phấn quá mức
Sentiment cải thiện liên tục	Có thể là tín hiệu momentum thông tin
Sentiment giảm mạnh	Có thể là tín hiệu rủi ro

Tuy nhiên, backtesting cần tính thêm chi phí giao dịch, độ trễ tin tức, khả năng mua bán thực tế và tránh look-ahead bias.

15.6 Kết luận về những điểm làm được trong dự án

1. Làm sạch và chuẩn hóa dữ liệu tin tức cổ phiếu giai đoạn 2010–2023.
2. Xây dựng tập 43.840 candidate terms và dictionary sentiment tài chính.
3. Gán sentiment label cho 126.576 bài báo.
4. Fine-tune mô hình PhoBERT với accuracy khoảng 85,5% trên tập kiểm thử.
5. Tính daily, weekly và monthly Equity Sentiment Index.
6. Tạo weekly return, abnormal return và dữ liệu merge với VN-Index.
7. Chạy predictive regression để kiểm tra tác động sentiment đến return tương lai.

Kết quả phân tích cho thấy sentiment index chưa có quan hệ rõ ở horizon 1 tuần, nhưng có tín hiệu âm đáng chú ý ở horizon 4 tuần, đặc biệt khi xét abnormal return. Điều này gợi ý rằng sentiment có thể là một biến bổ sung hữu ích trong phân tích thị trường, nhưng chưa đủ để sử dụng độc lập cho dự báo hoặc giao dịch. Các hướng phát triển tiếp theo nên tập trung vào kiểm định độ ổn định, cải thiện dictionary, bổ sung biến kiểm soát và xây dựng backtest thực tế.

CHƯƠNG 16

Công thức chính

16.1 Sentiment score bài báo

$$sentiment_score = \frac{positive_count - negative_count}{positive_count + negative_count}$$

16.2 Sentiment index theo kỳ

$$SI_t = \frac{1}{N_t} \sum_{i=1}^{N_t} score_{i,t}$$

16.3 Z-score sentiment index

$$SI_t^z = \frac{SI_t - \mu(SI)}{\sigma(SI)}$$

16.4 Weekly return

$$return_t = \ln \left(\frac{close_t}{close_{t-1}} \right)$$

16.5 Abnormal return

$$abnormal_return_t = actual_return_t - expected_return_t$$

16.6 Predictive regression

$$Y_{t+h} = \alpha + \beta_1 Sentiment_t + \beta_2 ReturnLag_t + \beta_3 Volatility_t + \beta_4 LogArticleCount_t + \epsilon_t$$

CHƯƠNG 17

Tài liệu tham khảo

- Baker, Malcolm, và Jeffrey Wurgler. 2006. “Investor Sentiment and the Cross-Section of Stock Returns”. *The Journal of Finance* 61 (4): 1645–80. <https://doi.org/10.1111/j.1540-6261.2006.00885.x>.
- Loughran, Tim, và Bill McDonald. 2011. “When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks”. *The Journal of Finance* 66 (1): 35–65. <https://doi.org/10.1111/j.1540-6261.2010.01625.x>.
- Nguyen, Dat Quoc, và Anh Tuan Nguyen. 2020. “PhoBERT: Pre-trained Language Models for Vietnamese”. *Findings of the Association for Computational Linguistics: EMNLP 2020*, 1037–42. <https://doi.org/10.18653/v1/2020.findings-emnlp.92>.
- Tetlock, Paul C. 2007. “Giving Content to Investor Sentiment: The Role of Media in the Stock Market”. *The Journal of Finance* 62 (3): 1139–68. <https://doi.org/10.1111/j.1540-6261.2007.01232.x>.