

Quy trình gán nhãn cảm xúc cho bài báo tài chính (article sentiment)

Ground Truth Sentiment Annotation Workflow

Doãn Khang


Table of contents

1. Mô tả tổng quan quy trình gán nhãn dữ liệu	2
1.1 Luồng dữ liệu	2
1.2 Thông tin project	3
2. Mục tiêu	3
3. Nhãn (Labels)	3
4. Quy trình Annotation	3
Cách vào:	3
Nhiệm vụ:	3
Nguyên tắc khi phân vân:	4
Sơ đồ quy trình:	4
Xử lý task bị Skip	6
5. Mẫu gán nhãn (Labeling Config)	6
6. Tiêu chí Quality Review	7
7. Checklist quy trình	7
7.1 Trước khi bắt đầu	7
7.2 Trong quá trình annotation	7
7.3 Sau khi annotation	7
8. Chi phí và thời gian dự kiến (tham khảo)	8
8.1 Giả định	8
8.2 Chi phí	8
8.3 Thời gian	8
8.4 Thu nhập theo giờ của annotator	8

1. Mô tả tổng quan quy trình gán nhãn dữ liệu

Bài toán chỉ có 1 bước: gán nhãn cảm xúc (Positive/Negative/Neutral) trực tiếp cho từng bài báo.

1.1 Luồng dữ liệu



1.2 Thông tin project

Thành phần	Mô tả
Tên project	ground_truth_sentiment
Nhãn cần gán	Positive / Negative / Neutral + Confidence (0–100)
Chỉ tiêu số lượng	1,000–5,000 bài gán nhãn ground truth
Output	Export JSON/CSV

2. Mục tiêu

Mục tiêu của việc gán nhãn ground_truth_sentiment:

1. Tạo **tập nhãn chuẩn do con người xác nhận** để đo độ chính xác thực tế của model.
2. Xa hơn: cải thiện độ tin cậy của **Equity Sentiment Index**, phục vụ phân tích tương quan/hồi quy với chỉ số VN-Index.
3. Chỉ tiêu số lượng: **1,000–5,000 bài** được gán nhãn ground truth.

3. Nhãn (Labels)

Mỗi task hiển thị **nội dung bài báo** và Annotator cần chọn một trong ba nhãn:

Nhãn	Mô tả
Positive	Tin tích cực cho doanh nghiệp/cổ phiếu (tăng trưởng, lãi tăng, cổ đông lớn mua vào, vượt kế hoạch, ký được hợp đồng lớn...)
Negative	Tin tiêu cực (thua lỗ, giảm doanh thu/lợi nhuận, bán tháo, không hoàn thành kế hoạch, bị phạt/kiện tụng...)
Neutral	Tin trung tính, chỉ mang tính thông báo/thống kê, không rõ tích cực hay tiêu cực (VD: công bố lịch họp ĐHĐCĐ, báo cáo định kỳ không có biến động đáng kể)

Kèm theo mỗi nhãn là **Độ tin cậy (Confidence, 0–100)** — mức độ chắc chắn của annotator với lựa chọn của mình (mặc định 80, kéo thanh trượt để điều chỉnh).

4. Quy trình Annotation

Cách vào:

1. Truy cập **QuestLab**
2. Đăng nhập bằng tài khoản được cấp.
3. Chọn project **ground_truth_sentiment**.
4. Bấm **Label All Tasks** để bắt đầu.


Nhiệm vụ:

1. Đọc nội dung bài báo.
2. Chọn nhãn cảm xúc **thực sự đúng** theo bạn phù hợp với ngữ cảnh tài chính
3. Kéo thanh trượt **Độ tin cậy (0–100)** để thể hiện mức độ chắc chắn.
4. Bấm **Submit** để xác nhận và chuyển sang bài tiếp theo.

Nguyên tắc khi phân vân:

- Đánh giá theo **tác động thực tế đến doanh nghiệp/cổ phiếu được nhắc tới**, không đánh giá theo văn phong hay từ ngữ đơn thuần.
- Nếu bài có cả tin tốt lẫn tin xấu, có thể bấm **Skip**
- **Tin tổng hợp nhiều doanh nghiệp** (VD: điểm tin thị trường, so sánh nhiều mã cổ phiếu cùng lúc):
 - Nếu tất cả doanh nghiệp được nhắc đều **cùng một xu hướng** (cùng tăng/cùng giảm) → vẫn gán nhãn theo xu hướng chung đó.
 - Nếu kết quả **trái chiều** giữa các doanh nghiệp (một số tăng, một số giảm) và không có doanh nghiệp nào là trọng tâm rõ ràng → bấm **Skip**, vì một nhãn duy nhất không phản ánh đúng cho bất kỳ mã cổ phiếu cụ thể nào, gán bừa sẽ gây nhiễu cho tập ground truth.
 - Nếu bài có **1 doanh nghiệp chính làm chủ thể** (thường nêu ở tiêu đề), các doanh nghiệp khác chỉ được nhắc để so sánh/bối cảnh → gán theo sentiment của doanh nghiệp chính, bỏ qua phần phụ.
- Nếu bài không đọc được / nội dung lỗi / không liên quan tài chính-chứng khoán → bấm **Skip**.

Sơ đồ quy trình:



(Không hợp lệ = lỗi/không liên quan/tin trái chiều không rõ trọng tâm — xem chi tiết ở phần “Nguyên tắc khi phân vân” phía trên. Quy trình lặp lại cho đến khi hết task trong queue.)

Xử lý task bị Skip

Một task bị Skip **không bị loại bỏ ngay** — hệ thống xử lý theo 2 hướng tùy số lần bị Skip:

- **Mới bị Skip bởi 1 annotator**: task tự động quay lại hàng đợi để **annotator thứ 2 kiểm tra lại** (không loại bỏ). Trong lúc chờ người thứ 2 xử lý, task được **đánh dấu (flag)** để tiện theo dõi.
 - Nếu annotator thứ 2 gán nhãn thành công (không Skip) → task được tính bình thường, nhãn của annotator thứ 2 là kết quả cuối cùng.
- **Bị Skip bởi cả 2 annotator** (annotator thứ 2 kiểm tra lại nhưng cũng Skip): xác nhận đây là task không thể gán nhãn được (dữ liệu lỗi, nội dung mơ hồ, hoặc không đủ thông tin) → **loại bỏ hẳn khỏi tập ground truth khi xuất file**, không tính vào kết quả cuối cùng.

5. Mẫu gán nhãn (Labeling Config)

Giao diện gán nhãn sử dụng **Choices** để chọn nhãn cảm xúc và **Number** (slider) để kéo thả độ tin cậy (0–100, mặc định 80). Cấu hình dưới đây mang tính **tham khảo** — nếu khác với giao diện thực tế trên Label Studio, cấu hình trong **Project Settings** ☐ **Labeling Interface** là chuẩn.

```
<View>
  <Header value="Bài báo"/>

  <Text
    name="content"
    value="$content"/>

  <Header value="Chọn cảm xúc"/>

  <Choices
    name="sentiment"
    toName="content"
    choice="single"
    required="true">

    <Choice value="Positive"/>
    <Choice value="Negative"/>
    <Choice value="Neutral"/>

  </Choices>

  <Header value="Độ tin cậy (Confidence)"/>

  <Text
    name="confidence_desc"
    value="0 = Đoán mò | 50 = Khá chắc chắn | 100 = Hoàn toàn chắc chắn"/>

  <Number
    name="confidence"
    toName="content"
    min="0"
    max="100"
    step="5"
    defaultValue="80"
```

```
slider="true"
required="true"/>
```

</View>

6. Tiêu chí Quality Review

Đây là quy trình **đề xuất** (hiện repo chưa có sẵn quy trình QA tự động), áp dụng khi số lượng annotator > 1 hoặc khi cần kiểm tra chất lượng trước khi dùng tập ground truth để train model.

- **Spot-check ngẫu nhiên:** định kỳ (VD: mỗi 500 task hoàn thành), admin lấy mẫu ngẫu nhiên ~10% annotation đã Submit để review lại tính hợp lý của nhãn.
- **Ưu tiên review các trường hợp:**
 - Độ tin cậy (confidence) thấp (< 50) — annotator tự đánh giá là không chắc chắn.
 - Task bị Skip nhiều lần liên tiếp bởi nhiều annotator khác nhau — có thể do dữ liệu lỗi/nhiều, cần loại khỏi tập.
- **Theo dõi theo từng annotator:**
 - Tỷ lệ Skip quá cao (VD: > 30%) so với mặt bằng chung → xem lại có phải do task thực sự khó, hay annotator chưa hiểu rõ tiêu chí.
 - Tốc độ gán nhãn bất thường (quá nhanh so với độ dài bài báo) → khả năng gán ẩu, cần review lại mẫu ngẫu nhiên của người đó. Căn cứ định lượng là trường **lead_time** — số giây Label Studio **tự động ghi lại cho mỗi annotation**, tính từ lúc task hiện ra đến lúc annotator bấm Submit. Quy ước: annotation có lead_time dưới ~20 giây (với bài báo dài vài đoạn) bị coi là gán ẩu và đưa vào diện review; nếu nhãn sai thì loại bỏ và không tính công lượt đó. Lưu ý lead_time có thể bị thổi phồng nếu annotator mở task rồi để đó làm việc khác, nên chỉ dùng làm tín hiệu sàng lọc, không phải bằng chứng tuyệt đối.
- **Đo độ đồng thuận (Inter-Annotator Agreement):** khi có ≥ 2 annotator, bật **overlap** cho một tập con nhỏ (VD: 5–10% task) để cùng gán nhãn độc lập, sau đó tính tỷ lệ đồng thuận (agreement rate) — làm căn cứ đánh giá độ tin cậy chung của tập ground truth.
- **Tiêu chí chấp nhận trước khi dùng để train model:** tỷ lệ Skip toàn bộ project không vượt quá ngưỡng đặt trước (VD: 20%), và đã spot-check xong toàn bộ các trường hợp bị flag ở trên.

7. Checklist quy trình

7.1 Trước khi bắt đầu

- Task đã được import đầy đủ vào project **ground_truth_sentiment**.
- Labeling Interface đã cấu hình đúng (nhấn Positive/Negative/Neutral + Confidence slider).
- Annotator đã được cấp tài khoản đăng nhập.
- Annotator đã đọc và hiểu rõ **Mục 3 (Nhãn)** và phần “**Nguyên tắc khi phân vân**” ở Mục 4.
- Đã thống nhất chỉ tiêu số lượng bài và deadline (nếu có) với annotator.

7.2 Trong quá trình annotation

- Theo dõi tiến độ qua QuestLab dashboard (số task đã Submit / còn lại / Skip).
- Định kỳ spot-check theo tiêu chí ở **Mục 6**.
- Giải đáp thắc mắc của annotator với các bài khó xác định (tin trái chiều, nhiều doanh nghiệp...).

7.3 Sau khi annotation

- Export dữ liệu đã gán nhãn (JSON/CSV) từ QuestLab.
- Loại bỏ các task bị Skip bởi cả 2 annotator, theo quy tắc ở phần “**Xử lý task bị Skip**”.
- Spot-check/QA toàn bộ trường hợp bị flag theo **Mục 6** trước khi coi là ground truth chính thức.
- Dùng tập ground truth để đo độ chính xác của model hiện tại và/hoặc cải thiện **Equity Sentiment Index**.

8. Chi phí và thời gian dự kiến (tham khảo)

Ước tính cho mục tiêu **5.000 bài**, mỗi bài được **2 annotator** gán độc lập.

8.1 Giả định

Tham số	Giá trị
Số bài	5.000
Số annotator / bài	2
Tổng số lượt gán	10.000
Đơn giá	300đ / lượt
Tốc độ giả định	30 giây / lượt
Số annotator làm song song	2

8.2 Chi phí

Khoản	Cách tính	Tiền
Gán nhãn chính	$10.000 \text{ lượt} \times 300\text{đ}$	3.000.000đ
Dự phòng Skip + requeue (~10%)	$\sim 1.000 \text{ lượt} \times 300\text{đ}$	$\sim 300.000\text{đ}$
Re-label các ca bị QA loại (~5%)	$\sim 500 \text{ lượt} \times 300\text{đ}$	$\sim 150.000\text{đ}$
Tổng nên chuẩn bị		$\sim 3,3\text{--}3,5$ triệu đồng

3 triệu là con số “sạch”; thực tế luôn phát sinh lượt lặp lại do Skip và QA.

8.3 Thời gian

Ở tốc độ 30 giây/lượt:

- Tổng công: $10.000 \text{ lượt} \times 30 \text{ giây} = \mathbf{5.000 \text{ phút} \approx 83 \text{ giờ}}$.
- Chia cho 2 annotator làm song song: **$\sim 42 \text{ giờ} / \text{người}$** .

Số giờ làm / ngày / người	Số ngày hoàn thành (chưa tính hao phí)
4 giờ	~ 11 ngày
5 giờ	$\sim 8\text{--}9$ ngày
6 giờ	~ 7 ngày
8 giờ (toàn thời gian)	~ 5 ngày

Cộng thêm $\sim 15\text{--}20\%$ cho Skip, nghỉ giải lao và hỏi đáp các ca khó:

- Bán thời gian (~ 5 giờ/ngày/người): **khoảng 2 tuần**.
- Toàn thời gian (~ 8 giờ/ngày/người): **khoảng 1–1,5 tuần**.

8.4 Thu nhập theo giờ của annotator

Ở tốc độ 30 giây/lượt $\rightarrow 120 \text{ lượt/giờ} \rightarrow \mathbf{36.000\text{đ/giờ/người}}$ (đơn giá là 300đ mỗi lượt, không phải mỗi giờ).

Nếu tốc độ thực tế chậm hơn thì thu nhập giờ giảm theo: $1 \text{ phút/lượt} \rightarrow 18.000\text{đ/giờ}$; $2 \text{ phút/lượt} \rightarrow 9.000\text{đ/giờ}$.

Lưu ý: 30 giây/lượt là rất nhanh cho một bài báo dài vài đoạn — mức này chỉ đủ để đọc lướt. Nếu muốn annotator đọc kỹ, tốc độ thực tế sẽ gần 1 phút/lượt hơn. Ngoài ra tốc độ kế hoạch 30 giây khá sát ngưỡng cảnh báo lead_time ~ 20 giây ở Mục 6, nên cần theo dõi chặt phân bố lead_time để phân biệt “làm nhanh nhưng vẫn đọc” với “gán ầu”.