

Quy trình gán nhãn dữ liệu phát hiện gian lận doanh nghiệp

Corporate Fraud Detection - Data Annotation Workflow

Vu Duc Hai

2026-03-07

Table of contents

1	Mô tả tổng quan quy trình gán nhãn dữ liệu	3
1.1	Kiến trúc tổng thể	3
1.2	Crawl & Lưu trữ	4
2	Project 1 - Phân loại bài báo (Phân loại Nhị phân - Binary Classification)	4
2.1	Mục tiêu	4
2.2	Nhãn (Labels)	4
2.3	Quy trình Annotation	4
2.4	Mẫu gán nhãn giai đoạn 1	5
2.5	Tiêu chí Quality Review	6
3	Bước trung gian - Lọc & Chuẩn bị dữ liệu cho Project 2	6
3.1	Logic:	6
3.2	Tài liệu	7
4	Project 2 — NER & Phân loại loại gian lận	7
4.1	Mục tiêu	7
4.2	Nhãn (Labels)	7
4.2.1	Nhãn Thực thể (Entities)	7
4.2.2	Nhãn Phân loại (Fraud Types)	7
4.3	Quy trình Annotation	8
4.4	Mẫu gán nhãn giai đoạn 2	9
4.5	Tiêu chí Quality Review	9
5	Bước kết thúc — Merge final dataset	10
5.1	Logic:	10
5.2	Tài liệu	10
5.3	Schema Final Dataset	10
6	Checklist quy trình	11
6.1	Trước khi bắt đầu	11

6.2	Trong quá trình annotation	11
6.3	Sau khi annotation	11
7	Phụ lục	12
7.1	Thống kê kế hoạch gán nhãn & chi phí	12

1 Mô tả tổng quan quy trình gán nhãn dữ liệu

Hệ thống gán nhãn dữ liệu phát hiện gian lận doanh nghiệp từ tin tức được thiết kế theo mô hình **2 giai đoạn** trên Label Studio nhằm phân loại (fraud - non fraud) và trích xuất thông tin từ các bài báo liên quan đến gian lận (fraud types). Mỗi giai đoạn được chia thành 1 dự án (do bản Community không hỗ trợ tích hợp nhiều dự án). Hai dự án được kết nối với nhau qua bộ script xử lý trung gian và một số thao tác thủ công trên ứng dụng từ admin.




Figure 1: Tổng quan quy trình

1.1 Kiến trúc tổng thể

Thành phần	Mô tả
Nguồn dữ liệu	Tin tức từ các trang báo điện tử (12 đầu báo được khai thác bởi DataCore)
Lưu trữ	MinIO / AWS S3 (HTML files)
Annotation Tool	Label Studio (2 Project)
Script	Python file
Output	JSON files

1.2 Crawl & Lưu trữ

- Bài báo được crawl từ các trang tin tức, lưu dưới dạng HTML
- Đồng bộ lên MinIO / AWS S3 làm kho lưu trữ trung tâm
- Label Studio load task trực tiếp từ S3

2 Project 1 - Phân loại bài báo (Phân loại Nhị phân - Binary Classification)

Tên project: S1_CNews_Fraud_html

2.1 Mục tiêu

Xác định bài báo có liên quan đến **gian lận doanh nghiệp** hay không.

2.2 Nhãn (Labels)

Mỗi bài báo được gán một trong hai nhãn.

Nhãn	Mô tả
Fraud	Nội dung bài báo đề cập đến một vụ việc, hành vi, các hoạt động hoặc dấu hiệu gian lận, lừa đảo và vi phạm pháp luật
Non-Fraud	Bài báo không liên quan đến tính chất gian lận hoặc chỉ đề cập đến các nội dung thông thường

2.3 Quy trình Annotation

1. **Load Tasks** - Sync HTML articles từ S3 vào Label Studio thành các tasks
2. **Annotate** - Annotator đọc bài theo task và gán nhãn **Fraud** / **Non-Fraud**
3. **Quality Review** - Kiểm tra chất lượng các tasks theo các rule được thiết lập sẵn
4. **Export** - Xuất dữ liệu đã được gán nhãn và đã được đánh giá chất lượng dưới dạng JSON

2.4 Mẫu gán nhãn giai đoạn 1

Mẫu sử dụng **Choice** để tích phân loại và **Slider** để kéo thả độ tự tin của người gán nhãn về lựa chọn của mình (dao động từ 0-100 và bước 5 đơn vị).

```
<View>

  <Header value="Article"/>

  <HyperText
    name="html"
    value="$html"
    valueType="url"/>

  <Header value="Fraud Classification"/>

  <Choices
    name="fraud"
    toName="html"
    choice="single"
    required="true">

    <Choice value="Fraud"/>
    <Choice value="Non-Fraud"/>

  </Choices>

  <Header value="Confidence in your label"/>

  <Text
    name="confidence_desc"
    value="0 = Pure guess | 50 = Moderate confidence | 100 = Certain"/>

  <Number
    name="confidence"
    toName="html"
    min="0"
    max="100"
    step="5"
    slider="true"
    required="true"/>

</View>
```



Fraud Classification

☐ **Fraud^[1]**

☐ **Non-Fraud^[2]**

Confidence in your label

0 = Pure guess | 50 = Moderate confidence | 100 = Certain

Progress bar showing confidence level (slider knob is at approximately 25%).

Figure 2: Giai đoạn 1

2.5 Tiêu chí Quality Review

- Không có bài bị bỏ sót (skipped tasks = 0)
- Mỗi task có tối thiểu 3 annotators
- Chỉ số đánh giá và lựa chọn dựa vào document của anh Mike Nguyen (tài liệu khác)

3 Bước trung gian - Lọc & Chuẩn bị dữ liệu cho Project 2

Script: `processing_p1_p2.py`

3.1 Logic:

1. Đọc JSON export từ Project 1
2. Lọc các annotation có nhãn `== Fraud`
3. Lấy thông tin URL / nội dung bài
4. Chuẩn bị task format cho Project 2

Lưu ý: Giữ nguyên URL bài báo (`html`) và id gốc từ Project 1 (`meta_project1_id`)

3.2 Tài liệu

Loại	Mô tả
Mã	<code>processing_p1_p2.py</code>
Input	<code>label_p1.json</code> - tệp chứa các tasks được gán nhãn sau project 1
Processing	<code>fraud_only.json</code> - tệp chứa các task chỉ có nhãn Fraud
Output	<code>p2_import.json</code> - tệp đồng bộ thông tin, là đầu vào cho project 2

4 Project 2 — NER & Phân loại loại gian lận

Tên project: `S2_CNews_Fraud_html`

4.1 Mục tiêu

Chỉ áp dụng đối với các bài báo đã được gán nhãn **Fraud** ở Project 1. Với các bài đã xác định là **Fraud**, Annotator sẽ thực hiện đánh dấu (highlight) các thực thể xuất hiện trong nội dung bài báo và gán nhãn theo bộ nhãn (label set) đã được định nghĩa trước:

1. **NER (Named Entity Recognition)** - Xác định các thực thể liên quan
2. **Fraud Type Classification** - Phân loại loại gian lận (multi-label, 7 nhãn)

4.2 Nhãn (Labels)

4.2.1 Nhãn Thực thể (Entities)

Phiên bản hiện tại chỉ để 1 dạng nhãn chủ thể đại diện cho tất cả (tổ chức, doanh nghiệp, cá nhân), gọi là thực thể **Entity**.

4.2.2 Nhãn Phân loại (Fraud Types)

Nhãn phân loại 7 loại gian lận.

#	Fraud Type	Mô tả
1	Tax Evasion and Tax Fraud	Cố tình che giấu doanh thu, khai khống chi phí, hoặc dùng thủ đoạn gian dối để giảm thiểu/trốn tránh nghĩa vụ thuế với Nhà nước
2	Invoice Fraud	Tạo lập, sử dụng hoặc mua bán hóa đơn khống để thao túng sổ sách kế toán, khai khống chi phí, hoặc tiếp tay cho gian lận thuế
3	Accounting Fraud	Cố tình trình bày sai lệch hoặc che giấu sổ sách kế toán, báo cáo tài chính nhằm bóp méo tình hình tài chính thực của doanh nghiệp
4	Procurement Fraud	Hành vi gian lận hoặc thông đồng trong đấu thầu công/tư nhằm giành lợi thế không công bằng hoặc trúng thầu trái phép
5	Criminal Fraud	Cố tình lừa dối đối tác, khách hàng hoặc nhà đầu tư để chiếm đoạt tài sản, bao gồm biển thủ và các hình thức chiếm dụng khác
6	Securities Fraud	Hành vi gian lận trong phát hành, giao dịch hoặc công bố thông tin chứng khoán nhằm đánh lừa nhà đầu tư hoặc thao túng thị trường vốn
7	Legal Enforcement	Tổng hợp các vi phạm dẫn đến truy tố hình sự, phản ánh tình trạng pháp lý của một hoặc nhiều hành vi gian lận cấu thành

4.3 Quy trình Annotation

1. **Load Tasks** - Import file kết quả của bước trung gian vào Project 2
2. **Annotate** - Annotator thực hiện chọn thực thể, loại gian lận và nối mối quan hệ giữa chúng
3. **Quality Review** - Kiểm tra chất lượng các tasks theo các rule được thiết lập sẵn
4. **Export** - Xuất dữ liệu đã được gán nhãn và đã được đánh giá chất lượng dưới dạng JSON

4.4 Mẫu gán nhãn giai đoạn 2

Mẫu sử dụng **Label** để bôi màu trực tiếp lên nội dung tin tức, qua đó thu được loại nhãn đi kèm nội dung tương ứng.

```
<View>
  <HyperTextLabels
    name="label"
    toName="html">

    <Label value="Entity" background="#607D8B"/>

    <Label value="Tax Evasion and Tax Fraud" background="#2E7D32"/>
    <Label value="Invoice Fraud" background="#E53935"/>
    <Label value="Accounting Fraud" background="#1E88E5"/>
    <Label value="Procurement Fraud" background="#EC407A"/>
    <Label value="Criminal Fraud" background="#8E24AA"/>
    <Label value="Securities Fraud" background="#F9A825"/>
    <Label value="Legal Enforcement" background="#6D4C41"/>

  </HyperTextLabels>

  <HyperText
    name="html"
    value="$html"
    valueType="url"/>
</View>
```




Figure 3: Giai đoạn 2

4.5 Tiêu chí Quality Review

- Mỗi bài có ít nhất 1 Fraud Type được chọn, không giới hạn số lượng tối đa
- Không có bài bị bỏ sót (skipped tasks = 0)
- Mỗi task có tối thiểu 3 annotators
- Chỉ số đánh giá và lựa chọn dựa vào document của anh Mike Nguyen (tài liệu khác)

5 Bước kết thúc — Merge final dataset

Script: `merge_labels.py`

5.1 Logic:

1. Đọc JSON export từ Project 1 và Project 2
2. Build index Project 2 theo S3 URL (`data.html`)
3. Với mỗi task Project 1, lấy `label_fraud` / `label_confidence`, nếu là Fraud thì tìm task tương ứng ở Project 2 theo URL và tách nhãn `Entity` / `Fraud Type`
4. Giữ lại task `Non-Fraud` (chỉ cần Project 1) và task `Fraud` đã xong giai đoạn 2 (có `Fraud Type`), loại bỏ task `Fraud` chưa được annotate ở Project 2

Lưu ý: Match 2 project theo S3 URL (`data.html`), không dùng `article_id` riêng

5.2 Tài liệu

Loại	Mô tả
Mã	<code>merge_labels.py</code>
Input 1	<code>label_p1.json</code> - tệp export từ Project 1 (Fraud/Non-Fraud + confidence)
Input 2	<code>label_p2.json</code> - tệp export từ Project 2 (Entity + Fraud Type)
Output	<code>labeled_dataset.json</code> - final dataset gồm task Non-Fraud (P1) và task Fraud đã xong 2 giai đoạn (P1 + P2)

5.3 Schema Final Dataset

```
{
  "metadata": {
    "created_at": "2026-07-08T00:00:00+00:00",
    "source_project1": "label_p1.json",
    "source_project2": "label_p2.json",
    "total_tasks_project1": 0,
    "fraud_tasks_project1": 0,
    "non_fraud_tasks": 0,
    "fraud_matched_with_project2": 0,
    "fraud_not_yet_annotated_in_project2": 0,
    "total_tasks_in_final_dataset": 0
  },
  "data": [
    {
```

```

    "id": 0,
    "s3_url": "string",
    "label_fraud": "Fraud | Non-Fraud",
    "label_confidence": 0,
    "label_entities": [
      {
        "text": "string",
        "labels": ["Entity"],
        "startOffset": 0,
        "endOffset": 0
      }
    ],
    "label_fraud_types": ["Tax Evasion and Tax Fraud", "..."],
    "project1_annotation_id": 0,
    "project2_annotation_id": 0,
    "created_at": "string",
    "updated_at": "string"
  }
]
}

```

6 Checklist quy trình

6.1 Trước khi bắt đầu

- S3/MinIO đã sync đủ bài báo HTML
- Label Studio Project 1 đã cấu hình đúng labeling config
- Label Studio Project 2 đã cấu hình đúng labeling config (NER + Fraud Types)
- Annotators đã được training và test calibration

6.2 Trong quá trình annotation

- Monitor tiến độ qua Label Studio dashboard
- Chạy quality review định kỳ
- Giải quyết các trường hợp bất đồng

6.3 Sau khi annotation

- Export JSON từ cả 2 project
 - Chạy `processing_p1_p2.py` → `merge_labels.py`
 - Validate final dataset
-

7 Phụ lục

7.1 Thống kê kế hoạch gán nhãn & chi phí

Tham chiếu kế hoạch & chi phí tại: `questlab_labeling_plan`