

Tóm tắt phương pháp Lexicon-Based

Mục lục

PHẦN 1 — Scoring: trọng số PMI + xử lý ngữ cảnh (Scoring/)	2
1. Kết quả Phần 1 (đối chiếu 599 bài ground truth, xem mục 6)	2
PHẦN 2 — Scoring Intensity: trọng số nội tại kiểu VADER (Scoring_Intensity/)	2
2. Kết quả Phần 2 (đối chiếu 599 bài ground truth, xem mục 6)	2
3. So sánh tổng hợp Phần 1 vs Phần 2 (số liệu cập nhật, xem mục 6)	2
4. Liên hệ tài liệu tham khảo (REF)	2
5. Hạn chế đã biết & việc đang chờ	3
6. Cải tiến mới (sau khi mở rộng ground truth + sửa bug)	3
7. Kiểm định ở cấp chỉ số ngày/tuần (News_Vnindex/) — chạy lại với lexicon đã sửa bug	5

PHẦN 1 — Scoring: trọng số PMI + xử lý ngữ cảnh (Scoring/)

1. Kết quả Phần 1 (đối chiếu 599 bài ground truth, xem mục 6)

Tập đánh giá	Accuracy
Toàn bộ 599 bài	60,4%
Chỉ tập Holdout (180 bài, khách quan nhất)	58,9%

PHẦN 2 — Scoring Intensity: trọng số nội tại kiểu VADER (Scoring_Intensity/)

2. Kết quả Phần 2 (đối chiếu 599 bài ground truth, xem mục 6)

Tập đánh giá	Accuracy
Toàn bộ 599 bài	60,3%
Chỉ tập Holdout (180 bài, khách quan nhất)	58,9%

“Dò 125 tổ hợp hệ số” nghĩa là gì: grid-search — thử toàn bộ tổ hợp thay vì đoán tay. 3 tham số của công thức, mỗi tham số 5 giá trị: `base_weight` (5 cách gán mức trọng số theo round), `marker_delta` $\in [0.0, 0.5, 1.0, 1.5, 2.0]$, `intensifier_scale` $\in [0.0, 0.5, 1.0, 1.5, 2.0]$ $\rightarrow 5 \times 5 \times 5 = 125$ tổ hợp (kết quả cập nhật sau khi tune đúng cách trên Tune/Holdout — xem mục 6 — vẫn giữ nguyên cấu hình production hiện tại, không đổi).

3. So sánh tổng hợp Phần 1 vs Phần 2 (số liệu cập nhật, xem mục 6)

	Phần 1 (PMI)	Phần 2 (nội tại)
Accuracy trên 599 bài	60,4%	60,3%
Accuracy trên Holdout (180 bài, khách quan nhất)	58,9%	58,9%

2 cách hiện cho kết quả gần như ngang nhau khi đánh giá khách quan trên Holdout — khác với chênh lệch 2 điểm % từng thấy trên 152 bài cũ.

4. Liên hệ tài liệu tham khảo (REF)

- Loughran & McDonald (2011), “*When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks*”, JF — khung 7-category gốc, đơn vị đo `count/N_total` (dùng

ở cả Phần 1 và Phần 2).

- **Tetlock (2007)**, “*Giving Content to Investor Sentiment*”, JF — cơ sở cho việc dùng ngôn ngữ media để đo sentiment tác động thị trường.
- **Baker & Wurgler (2006)**, “*Investor Sentiment and the Cross-Section of Stock Returns*”, JF — bối cảnh ứng dụng investor sentiment.
- **VADER** (Hutto & Gilbert) — ý tưởng trọng số nội tại theo từ + hệ số nhấn mạnh/phủ định, áp dụng ở Phần 2.
- **SentProp** (Hamilton, Clark, Leskovec, Jurafsky 2016) — hướng thay thế PMI bằng embedding + label propagation, đã tìm hiểu, **chưa triển khai** (cần train embedding riêng trên corpus, xem mục 5).

5. Hạn chế đã biết & việc đang chờ

1. Xem mục 6 cho các phát hiện/cải tiến mới nhất (ground truth mở rộng, tune/holdout, so sánh longest-match vs khớp chồng lấn, chẩn đoán Neutral).
2. 5 category còn lại (uncertainty/litigious/strong_modal/weak_modal/ constraining) chưa được đưa vào luật gán nhãn 3 lớp ở cả 2 phần — có thể là tín hiệu bổ sung hữu ích nhưng chưa thử nghiệm.
3. SentProp (embedding-based) chưa triển khai — hướng tiềm năng nếu Phần 1/2 hiện tại chưa đủ tốt khi có ground truth lớn.
4. Các hệ số cụ thể ở Phần 2 (base_weight theo vòng, hệ số nhấn mạnh) là quy tắc tự thiết kế, không phải do người/chuyên gia chấm độc lập từng từ như VADER gốc — dù đã tune/holdout xác nhận không cải thiện được thêm (mục 6), vẫn chưa được đánh giá bởi con người độc lập.

6. Cải tiến mới (sau khi mở rộng ground truth + sửa bug)

Bug đã sửa - ngram_n tính sai khiến 209 term (12,1%) không bao giờ khớp: build_weighted_dictionary.py và build_intensity_dictionary.py tính `ngram_n = term.count(" ") + 1` — đếm DẤU CÁCH, nhưng seed nối từ ghép bằng GẠCH DƯỚI theo quy ước VNCoreNLP. Với cụm KHÔNG phải compound thật của VNCoreNLP (VD tăng_mạnh, giảm_mạnh, có_lãi, nợ_xấu — tokenizer luôn tách thành 2 token rời, không gộp), bug gán nhầm `ngram_n=1`, term không bao giờ khớp được. Đã sửa bằng cách kiểm tra thật với tập token của corpus. Kết quả (chỉ sửa bug, không thêm/bớt từ nào): term “chết” giảm 209→141, Neutral_no_match/toàn corpus giảm 44,1%→37-41%, accuracy out-of-sample tăng ~1,6-2,5 điểm %.

Ground truth mở rộng 152 → 599 bài: `ground_truth_combined.csv=ground_truth_labeled.csv (152)+ground_truth_news.csv (447)`, xác nhận 0 trùng `source_row_id`. Chia cố định **Tune**

419 / Holdout 180 (stratified theo sentiment, random_state=42, data/ground_truth_tune_holdout_sp

Tune/holdout cho toàn bộ tham số từng bị chọn in-sample trên 152 bài: mọi tham số dưới đây được chọn trên Tune, xác nhận lại trên Holdout (chưa từng xem lúc chọn):

Tham số	Tốt nhất trên Tune	Trên Holdout (tốt nhất vs hiện tại)	Kết luận
negation_window — Cách 1	window=10 (61,6%)	58,3% vs 58,9% (window=4)	Giữ =4
negation_window — Cách 2	window=10 (61,6%)	57,8% vs 58,9% (window=4)	Giữ =4
125 tổ hợp hệ số — Cách 2	production/marker=0/scale=60 = 55,6% (61,1%)	55,6% vs 58,9% (bằng nhau)	Giữ production
margin (Neutral) — Cách 1	0,0037 (64,2%)	57,2% vs 58,9% (margin=0)	Giữ =0
margin (Neutral) — Cách 2	0,0324 (64,2%)	57,2% vs 58,9% (margin=0)	Giữ =0

Cả 5 lần đều cho cùng 1 mẫu hình: tham số “đẹp trên Tune” luôn MẤT ĐIỂM trên Holdout — bằng chứng thực nghiệm nhiều lần cho đúng cảnh báo in-sample của mentor. Không tham số nào trong 5 tham số này cần đổi.

Longest-match vs khớp chồng lán — khác với 5 kết quả trên: test lại khớp chồng lán (đếm cả n-gram ngắn lẫn n-gram dài hơn chứa nó, VD vừa đếm nghĩa_vụ vừa đếm nghĩa_vụ công_bố) cho: Tune gần ngang nhau (60,9% vs 61,1%), nhưng Holdout khớp chồng lán **thắng rõ cả 2 phương pháp** (60,6% vs 58,9%, macro-F1 tăng 0,576→0,600) — khác hẳn 5 tham số trên (luôn thua trên Holdout). Thống kê: 1211/1345 cặp term chồng nhau trong dictionary là CÙNG category — có thể lý giải vì sao chồng lán hoạt động như 1 dạng khuếch đại tín hiệu thay vì chỉ gây nhiễu, dù về lý thuyết nghe giống “đếm trùng”. **CHƯA ĐỔI production** — Holdout 180 bài, sai số chuẩn accuracy $\sim \pm 7$ điểm %, tín hiệu đáng chú ý (nhất quán đúng hướng như phát hiện cũ trên 152 bài) nhưng chưa phải bằng chứng dứt khoát, cần thêm ground truth.

Chẩn đoán Neutral mập mờ (mentor điểm 7): tách Neutral_balanced (2 điểm khác 0, bằng nhau) vs Neutral_no_match (cả 2 điểm = 0, không khớp từ nào). Trong số bài bị gán Neutral: **96% là Neutral_no_match**, chỉ 4% thực sự “2 tín hiệu cân bằng”. Neutral_no_match đúng thật Neutral 72,5% — tức ~27,5% bài không khớp được từ nào thực ra là Positive/Negative bị bỏ sót. Đào sâu nguyên nhân (diagnose_missing_terms.py): phần lớn bài còn lại là **tin công bố sự kiện thuần túy** (trả cổ tức, lãnh đạo/cổ đông lớn đăng ký mua/bán cổ phiếu...) — sentiment suy ra từ KIẾN THỨC TÀI CHÍNH, không nằm ở từ ngữ trong bài → giới hạn cấu trúc thật của

lexicon, không phải do thiếu từ. Ứng viên từ đào được (cổ_đông, bán, mua, đăng_ký...) đều là danh từ thực thể/động từ giao dịch trung tính — thêm vào có rủi ro lặp lại lỗi over-predict như tăng/giảm.

Từ vựng chỉ theo đúng hướng LM: toàn bộ seed gốc dịch thẳng từ LM, bootstrap PMI chỉ mở rộng cụm 2-3 từ trong đúng 7 category đó — chưa thử nghiệm hướng khác (VD embedding-based SentProp, hoặc mở rộng unigram bằng thuật toán thay vì chỉ tay). Bootstrap PMI cũng đã bão hòa rõ rệt (số term duyệt được mỗi vòng: 625→513→127→32) — chạy thêm vòng 5 khó tìm được nhiều từ mới, không ưu tiên.

7. Kiểm định ở cấp chỉ số ngày/tuần (News_Vnindex/) — chạy lại với lexicon đã sửa bug

Sau khi dictionary được sửa (mục 6), chạy lại toàn bộ pipeline sentiment-index → merge VN-Index → hồi quy dự báo (News_Vnindex/) để xem cải tiến ở cấp bài báo có tạo ra tín hiệu dự báo thị trường không. Test trên **4 cách tính sentiment độc lập** (Cách 1 PMI, Cách 2 Intensity, PCA_PMI, PCA_Intensity) - chỉ coi 1 phát hiện là đáng tin nếu nhất quán ở **cả 4**.

Lợi suất (return) - không đổi kết luận cũ: daily $R^2=1,41\%$ (trước 1,36%), F-test sentiment $p=0,106$ (trước 0,19) - vẫn không có ý nghĩa thống kê. Lag4 “có tín hiệu” ở PMI/Intensity nhưng mất ở PCA (daily); weekly thì ngược lại - PMI/Intensity gần ngưỡng 10% nhưng PCA không có gì. Kết luận giữ nguyên: **không có bằng chứng dự báo lợi suất vững qua cả 4 phương pháp**, giới hạn nằm ở khả năng dự báo vốn dĩ rất thấp của lợi suất VN-Index (thị trường gần hiệu quả), không phải do chất lượng lexicon.

Volume (khối lượng giao dịch) - phát hiện ban đầu hấp dẫn nhưng không trụ được qua kiểm định chặt hơn: lấy cảm hứng từ target thứ 2 của Tetlock (2007) (pessimism dự báo được volume, dù dự báo return kém) - **chưa từng test trong project trước đây**.

1. *Vòng 1 (chưa control xu hướng):* sentiment lag gần nhất → volume ngày kế tiếp dương ở **cả 4 phương pháp** (hệ số 0,009-0,012), 2/4 có ý nghĩa ($p<0,02$). Test cả bản “volume cùng ngày” (dùng lag quá khứ) lẫn “volume tương lai” (dùng sentiment hôm nay) - 2 khung cho kết quả gần như giống hệt nhau, xác nhận không phải data leakage.
2. *Vòng 2 (thêm year fixed effect):* log_vol_total có tương quan **RẤT MẠNH** với thời gian (corr=0,93 - thị trường VN tăng trưởng volume tự nhiên qua 14 năm), sentiment_index_z cũng trôi nhẹ theo năm (corr=0,34)
 - 5 lag (5 ngày) không đủ hấp thụ xu hướng nhiều năm. Sau khi thêm 14 year-dummy: tín hiệu **chỉ còn sống ở Cách 1 PMI ($p=0,0096$) và Cách 2 Intensity ($p=0,0266$)**, **mất hẳn ở PCA_PMI/PCA_Intensity** ($p=0,30$ và $0,26$) - không đạt chuẩn nhất quán 4 phương pháp.

3. *Vòng 3 (tách khối ngoại/khối nội)*: dữ liệu gốc (data_Histo/vnindex_eda_output.csv) có sẵn buy_vol_foreign/ sell_vol_foreign nhưng chưa từng được đưa vào pipeline - đã bỏ sung. **Khối ngoại**: không có tín hiệu ở bất kỳ phương pháp nào ($p=0,28-0,63$, $R^2=72\%$). **Khối nội**: lặp lại đúng mẫu hình vòng 2 (có ở PMI/Intensity, $p=0,0007$ và $0,0023$; mất ở PCA, $p=0,19$ và $0,17$). Diễn giải hợp lý: corpus tin tức (88% từ vietstock.vn, tiếng Việt, cấp doanh nghiệp) có thể ảnh hưởng nhà đầu tư cá nhân trong nước nhiều hơn tổ chức nước ngoài - nhưng **vẫn chưa đủ chuẩn robust** (chỉ 2/4 phương pháp), nên đây là quan sát đáng ghi nhận chứ chưa phải kết luận chắc chắn.

Bug dữ liệu phát hiện dọc đường: build_vnindex_daily_abnormal_return.py có 1 tên cột (future_abnormal_ar1_ret_1d) bị chèn ~2000 ký tự văn bản quảng cáo không rõ nguồn gốc vào giữa chuỗi (không phải lỗi cú pháp nên script vẫn chạy được, chỉ tạo ra tên cột sai) - đã sửa, không ảnh hưởng đến các kết luận trên (cột lỗi không được dùng trong hồi quy chính).

Kết luận tổng: cải tiến lexicon (mục 6) không tạo ra tín hiệu dự báo lợi suất mới. Volume ban đầu trông hứa hẹn hơn (nhất quán ở cả 4 phương pháp) nhưng thu hẹp đáng kể sau khi kiểm soát đúng xu hướng thời gian - cuối cùng cũng không đạt chuẩn nhất quán 4 phương pháp đã áp dụng xuyên suốt project.