

Tóm tắt phương pháp Lexicon-Based

Mục lục

1. Xây dựng seed — bootstrap bán giám sát qua PMI (4 vòng)	2
PHẦN 1 — Scoring: trọng số PMI + xử lý ngữ cảnh (Scoring/)	2
2. Công thức trọng số — Cách 1 (PMI-based, biến thể ADD-ALPHA)	2
3. Cơ chế xử lý ngữ cảnh khi chấm điểm bài báo (Negation + ranh giới mệnh đề + longest-match)	2
4. Công thức tổng & gán nhãn 3 lớp	3
5. Kết quả Phần 1 (đối chiếu 152 bài ground truth thí điểm)	3
PHẦN 2 — Scoring Intensity: trọng số nội tại kiểu VADER (Scoring_Intensity/)	3
6. Công thức trọng số — Cách 2 (không dùng điểm tính được từ PMI)	3
7. Kết quả Phần 2 (đối chiếu 152 bài ground truth thí điểm)	4
8. So sánh tổng hợp Phần 1 vs Phần 2	4
9. Liên hệ tài liệu tham khảo (REF)	5
10. Hạn chế đã biết & việc đang chờ	5

1. Xây dựng seed — bootstrap bán giám sát qua PMI (4 vòng)

- **Seed gốc** được dịch từ bộ từ điển LM: 7 file, tổng ~410 từ, curate tay theo đúng 7 category LM.
- **Biến thể PMI dùng: ADD-ALPHA PMI (Laplace smoothing)** $PMI_{add-alpha} = \log_2 \left(\frac{(co_df + 1) \cdot N}{(df_candidate + 1) \cdot (df_seed + 1)} \right), \alpha=1.0$.
- **4 tầng tổng hợp điểm:** $PMI(candidate, real_form) \rightarrow \max$ theo $real_form$ cùng 1 seed $\rightarrow \text{mean}$ theo mọi seed trong category (raw_score) $\rightarrow$ **centering 2 chiều** (trừ row_mean theo candidate + trừ col_mean theo category, cộng $grand_mean$) để khử 2 loại bias: (a) candidate hiếm bị PMI thổi điểm đều trên mọi category, (b) category có PMI trung bình hệ thống cao/thấp hơn category khác.
- **Chọn ngưỡng theo percentile** (top 3%/category) để review đến khi bão hòa
- **Quy trình theo vòng:** mỗi vòng xuất file kiểm tra manual review.
- **Kết quả sau 4 vòng:** litigious 587 từ, negative 355, uncertainty 358, positive 165, constraining 176, weak_modal 48, strong_modal 40.

PHẦN 1 — Scoring: trọng số PMI + xử lý ngữ cảnh (Scoring/)

2. Công thức trọng số — Cách 1 (PMI-based, biến thể ADD-ALPHA)

$weight = score_centered$, điểm **add-alpha PMI** cho từ mở rộng, 1.0 cho từ seed gốc.

3. Cơ chế xử lý ngữ cảnh khi chấm điểm bài báo (Negation + ranh giới mệnh đề + longest-match)

- **Phủ định** (`negation_cue_words.txt`, nguồn học thuật: “*Function Words of Negation in Vietnamese*”, Tạp chí Ngôn ngữ và Đời sống): quét ngược tối đa 4 token trước mỗi từ match, đảo dấu nếu gặp cue-word phủ định. Đã test 2/3/4/5/6 token — 4 là điểm bão hòa (≥ 4 cho kết quả giống hệt nhau).
- **Chặn ranh giới mệnh đề** (`clause_boundary_words.txt`): corpus đã tokenize **không còn dấu câu** (đã kiểm tra thực tế), nên dùng từ nối tương phản (“nhưng”, “tuy_nhiên”, “mặc_dù”...) làm điểm dừng cứng khi quét ngược tìm phủ định, tránh phủ định ở mệnh đề trước lan sang mệnh đề sau (VD “mặc_dù lợi_nhuận giảm **nhưng** doanh_thu tăng mạnh”). ~0,6% số quyết định phủ định trên toàn corpus bị chặn đúng.
- **Greedy longest-match** (không chồng lấn): quét mỗi câu ưu tiên khớp n-gram dài nhất trước, tránh đếm trùng vừa “hoạt_động” riêng lẻ vừa “tạm_ngừng hoạt_động” chứa nó trong cùng câu.

4. Công thức tổng & gán nhãn 3 lớp

$$S_{\text{category}} = (\sum \text{weight}(w) \times \text{sign}(w)) / N_{\text{total}}$$

N_{total} = tổng token bài báo (chuẩn hóa độ dài). $\text{sign} = -1$ nếu bị phủ định (mục 3), ngược lại +1.

Gán nhãn 3 lớp (“Cách 3”) — so sánh trực tiếp positive_score vs negative_score , không dùng ngưỡng đệm tùy tiện (đã thử thêm vùng đệm quanh 0, cải thiện không đáng kể/không nhất quán):

```
positive_score > negative_score -> Positive  
positive_score < negative_score -> Negative  
bằng nhau (kể cả 0-0)          -> Neutral
```

5 category còn lại (uncertainty, litigious, strong_modal, weak_modal, constraining) giữ điểm riêng, hiện **chưa đưa vào luật gán nhãn 3 lớp**.

5. Kết quả Phần 1 (đối chiếu 152 bài ground truth thí điểm)

Ban đầu | 63,8% (macro-F1 nhích nhẹ) |

Sau khi đổi sang greedy longest-match | 61,2% |

PHẦN 2 — Scoring Intensity: trọng số nội tại kiểu VADER (Scoring_Intensity/)

6. Công thức trọng số — Cách 2 (không dùng điểm tính được từ PMI)

Cách 2 vẫn **gián tiếp thừa hưởng thứ tự ưu tiên** ($\text{final_seed} > \text{round1} > \dots > \text{round4}$) từ PMI, dù không cộng thẳng con số PMI vào công thức.

Vì tiếng Việt chưa có sẵn lexicon kiểu VADER/AFINN cho tài chính, xây dựng quy tắc tường minh (rule-based) gồm 2 lớp:

- base_weight theo **vòng duyệt** (final_seed cao nhất $\rightarrow$ round4 thấp nhất) — từ càng “gốc/trung tâm” trọng số càng cao.
- marker_adjustment : +/- theo có chứa từ mang nghĩa cực đoan (VD “tuyệt_đối”, “phá_sản”) hay nhẹ (VD “hơi”, “tương_đối”) hay không.
- **Thêm hệ số nhân từ nhấn mạnh** ($\text{Intensifier_words}/$, có nguồn tham khảo chương trình Ngữ văn 6-7 cho nhóm “rất/quá/lắm...”): “rất tăng trưởng” được nhân hệ số lên so với “tăng trưởng” đứng một mình.

- Đã dò **125 tổ hợp hệ số** ($\text{base_weight} \times \text{marker_delta} \times \text{intensifier_scale}$) trên 152 mẫu ground truth (không tạo file trung gian), áp cấu hình tốt nhất rồi chạy lại qua **đúng pipeline chấm điểm chính thức** trên toàn bộ 126.576 bài để đối chiếu

Công thức tổng:

$$S_{\text{category}} = (\sum \text{weight}(w) \times \text{intensifier_multiplier}(w) \times \text{sign}(w)) / N_{\text{total}}$$

weight và $\text{intensifier_multiplier}$ là 2 điểm khác Phần 1; **phần còn lại (xử lý phủ định, ranh giới mệnh đề, longest-match, gán nhãn 3 lớp) dùng lại NGUYỄN cơ chế đã mô tả ở mục 3-4 Phần 1**, không xây riêng.

7. Kết quả Phần 2 (đối chiếu 152 bài ground truth thí điểm)

Bước	Accuracy
Cấu hình rule-based ban đầu	61,8%
Sau khi dò 125 tổ hợp hệ số	63,2% (đánh giá trên đúng 152 bài có nhãn, sau khi chạy qua pipeline chính thức)

“Dò 125 tổ hợp hệ số” nghĩa là gì: grid-search — thử toàn bộ tổ hợp thay vì đoán tay. 3 tham số của công thức, mỗi tham số 5 giá trị: base_weight (5 cách gán mức trọng số theo round), $\text{marker_delta} \in [0.0, 0.5, 1.0, 1.5, 2.0]$, $\text{intensifier_scale} \in [0.0, 0.5, 1.0, 1.5, 2.0] \rightarrow 5 \times 5 \times 5 = 125$ tổ hợp. `tune_intensity_coefficients.py` chạy lần lượt cả 125 tổ hợp, mỗi tổ hợp chỉ chấm nhanh trên 152 bài ground truth (không quét toàn bộ corpus, không tạo file trung gian cho từng tổ hợp), so accuracy để chọn tổ hợp tốt nhất. Tổ hợp thắng: base_weight dốc hơn cấu hình gốc, $\text{marker_delta}=0.0$ (tắt hẳn điều chỉnh marker — phát hiện bất ngờ), $\text{intensifier_scale}=1.0$ (giữ nguyên).

8. So sánh tổng hợp Phần 1 vs Phần 2

	Phần 1 (PMI)	Phần 2 (nội tại)
Accuracy tốt nhất hiện tại	61,2%*	63,2%

*Phần 1 từng đạt 63,8% trước khi đổi sang longest-match

Phân phối nhãn dự đoán trên toàn bộ 126.576 bài của cả 2 phần hiện tương đối cân bằng (~37% Positive/17% Negative/46% Neutral), không lệch cực đoan về 1 phía.

9. Liên hệ tài liệu tham khảo (REF)

- **Loughran & McDonald (2011)**, “*When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks*”, JF — khung 7-category gốc, đơn vị đo count/N_total (dùng ở cả Phần 1 và Phần 2).
- **Tetlock (2007)**, “*Giving Content to Investor Sentiment*”, JF — cơ sở cho việc dùng ngôn ngữ media để đo sentiment tác động thị trường.
- **Baker & Wurgler (2006)**, “*Investor Sentiment and the Cross-Section of Stock Returns*”, JF — bối cảnh ứng dụng investor sentiment.
- **VADER** (Hutto & Gilbert) — ý tưởng trọng số nội tại theo từ + hệ số nhấn mạnh/phủ định, áp dụng ở Phần 2.
- **SentProp** (Hamilton, Clark, Leskovec, Jurafsky 2016) — hướng thay thế PMI bằng embedding + label propagation, đã tìm hiểu, **chưa triển khai** (cần train embedding riêng trên corpus, xem mục 10).

10. Hạn chế đã biết & việc đang chờ

1. **Đang chờ bộ ground truth đầy đủ** hơn để đánh giá chính thức — 152 bài hiện tại chỉ là mẫu thí điểm, nhiều lần tinh chỉnh (margin, negation window, hệ số Phần 2) có rủi ro overfit vào đúng mẫu nhỏ này, cần tập lớn hơn để xác nhận các lựa chọn có tổng quát hóa tốt không.
2. Phần 1 sau khi đổi sang longest-match bị giảm nhẹ so với bản khớp chồng lần cũ (63,8%→61,2%) — chưa rõ đây là nhiều do mẫu nhỏ hay longest-match thực sự kém hơn, cần dữ liệu lớn hơn để kết luận.
3. 5 category còn lại (uncertainty/litigious/strong_modal/weak_modal/ constraining) chưa được đưa vào luật gán nhãn 3 lớp ở cả 2 phần — có thể là tín hiệu bổ sung hữu ích nhưng chưa thử nghiệm.
4. SentProp (embedding-based) chưa triển khai — hướng tiềm năng nếu Phần 1/2 hiện tại chưa đủ tốt khi có ground truth lớn.
5. Các hệ số cụ thể ở Phần 2 (base_weight theo vòng, hệ số nhấn mạnh) là quy tắc tự thiết kế + tinh chỉnh trên 152 mẫu, không phải do người/chuyên gia chấm độc lập từng từ như VADER gốc — cần đánh giá lại khi có thêm dữ liệu.