

Tóm tắt phương pháp Traditional ML

Mục lục

1. Bối cảnh và vị trí của phương pháp	2
2. Dữ liệu	2
3. Đặc trưng (features)	2
3.1. N-gram + lọc từ vựng	2
3.2. Công thức TF-IDF	2
4. Mô hình	3
5. Đánh giá – điểm mấu chốt về phương pháp	3
6. Kết quả (5-fold CV, tokenizer VNCORENLP)	4
7. Các quyết định thiết kế và lý do	4
8. Hướng cải tiến khi có thêm ground truth	5
9. Tham khảo	6

1. Bối cảnh và vị trí của phương pháp

Dự án đo sentiment tin tức chứng khoán Việt Nam rồi phân tích tác động lên VN-Index. Việc gán nhãn sentiment cấp bài (positive / negative / neutral) được làm theo **bốn hướng độc lập để so sánh**:

1. Lexicon-based (từ điển + công thức) — baseline.
2. **Traditional ML (TF-IDF + classifier)** — **nội dung tài liệu này**.
3. Transfer Learning (fine-tune PhoBERT).
4. PCA-based index (tổng hợp, ở tầng chỉ số).

Traditional ML đóng vai **baseline có giám sát, giải thích được**: bag-of-words + TF-IDF + mô hình tuyến tính/cây, để đối chiếu công bằng với Lexicon và Transformer trên cùng một tập ground truth.

2. Dữ liệu

Ground truth	152 bài gán nhãn tay trên Label Studio
Phân bố nhãn	negative 49 (32%), neutral 68 (45%), positive 35 (23%)

3. Đặc trưng (features)

3.1. N-gram + lọc từ vựng

- N-gram **1–3** trên token tiếng Việt.
- Lọc từ vựng (vocabulary):
 - min_df **theo tỷ lệ** số tài liệu ({1-gram: 2%, 2-gram: 1.3%, 3-gram: 1.3%}, sản tối thiểu 2 tài liệu)
 - max_df_ratio = 0.85 – bỏ term xuất hiện hơn 85% số bài (quá phổ biến, vô ích cho phân loại).
 - Bỏ stopword tiếng Việt; bỏ token dạng số / shape lỗi.
- Từ vựng thực tế: **1.468 term** (449 unigram / 630 bigram / 389 trigram) khi fit trên toàn bộ 152 bài.

3.2. Công thức TF-IDF

Dùng đúng công thức trọng số của **Loughran & McDonald (2011)** cho văn bản tài chính:

$$w_{i,j} = \frac{1 + \log(\text{tf}_{i,j})}{1 + \log(a_j)} \cdot \log \frac{N}{\text{df}_i} \quad \text{nếu } \text{tf}_{i,j} \geq 1$$

- $\text{tf}_{i,j}$: số lần term i xuất hiện trong bài j ; log giảm ảnh hưởng của term lặp nhiều lần.
- a_j : tổng số token (trong từ vựng) của bài j – chuẩn hoá độ dài, để bài dài và bài ngắn so được với nhau.
- $\log(N/\text{df}_i)$: IDF – term hiếm (df nhỏ) được coi trọng hơn, term phổ biến bị hạ gần 0.

4. Mô hình

Bốn classifier chạy trên cùng một quy trình đặc trưng, để so sánh:

Model	Cấu hình
Logistic Regression	<code>C = 1, class_weight = balanced</code>
Multinomial Naive Bayes	mặc định
Random Forest	300 cây, <code>class_weight = balanced</code>
Linear SVM	<code>LinearSVC + Platt calibration</code> để có xác suất, <code>class_weight = balanced</code>

Tất cả dùng `class_weight = balanced` để bù lớp positive ít dữ liệu.

Đầu ra mỗi bài: nhãn dự đoán + xác suất 3 lớp, và `sentiment_score_ml = P(positive) – P(negative)`.

5. Đánh giá – điểm mấu chốt về phương pháp

5-fold stratified cross-validation (mỗi fold giữ nguyên tỷ lệ 3 lớp). Không có test hold-out riêng vì 152 dòng quá ít; CV cho mỗi bài được dự đoán đúng một lần khi nó nằm ở fold validation, rồi gộp lại tính metric trên toàn bộ 152.

Không rò rỉ dữ liệu (data leakage). Đây là điểm được xử lý kỹ:

- Từ vựng, df, idf và bước chọn feature được **fit lại riêng trong từng train-fold** (khoảng 121 bài), rồi mới transform lên fold validation.
- Term chỉ xuất hiện trong fold validation thì không vào từ vựng, bị bỏ qua khi transform (đúng như tình huống gặp bài mới ngoài đời).
- `idf = log(n_train / df_train)`, mẫu số là số bài **train**, không tính validation.
- Một đường CV chung cho cả 4 model; `n_splits = min(5, số dòng lớp nhỏ nhất)`.

Chỉ số báo cáo. Macro-F1 (chính), accuracy, precision/recall/F1 từng lớp, confusion matrix.

6. Kết quả (5-fold CV, tokenizer VNCORENLP)

Model	Macro F1	Accuracy	F1 negative	F1 neutral	F1 positive
Random Forest	0.634	0.658	0.625	0.721	0.557
Naive Bayes	0.605	0.632	0.673	0.686	0.455
Logistic Regression	0.593	0.632	0.674	0.684	0.421
SVM	0.562	0.638	0.667	0.716	0.304

Nhận xét.

- Random Forest ổn định nhất qua cả 3 lớp.
- Lớp **positive yếu nhất** ở mọi model (F1 0.30–0.56). Ngoài lý do ít dữ liệu (35 bài), đây còn là hiện tượng đã ghi nhận trong tài liệu: Loughran & McDonald (2011), Tetlock (2007), Engelberg (2008) đều thấy **từ ngữ tích cực trong tin tài chính ít giá trị thông tin** vì hay bị phủ định (“không hoàn thành kế hoạch”). Nên yếu ở lớp positive **một phần là bản chất bài toán**.
- Các con số dao động khoảng 0.02 macro-F1 giữa các lần chia fold khác nhau, nên với 152 dòng **chưa kết luận chắc chắn model nào tốt hơn**.

Một thí nghiệm khác em đã làm (để từ vựng gọn hơn: bỏ trigram + nâng min_df sàn) giảm từ vựng 50% nhưng macro-F1 gần như không đổi (trung bình +0.006), xác nhận vocab “rác” không phải nút thắt; **nút thắt là số lượng ground truth**.

7. Các quyết định thiết kế và lý do

Quyết định	Lý do	Tham chiếu
Công thức TF-IDF $(1 + \log tf) / (1 + \log a_j) \times \log(N/df)$	Chuẩn textual analysis tài chính, xử lý attenuation bias	Loughran & McDonald 2011, eq. (1)
max_df 0.85 + IDF	Giảm ảnh hưởng từ tần suất cao	LM 2011
TF-IDF + chọn feature fit trong từng fold	Tránh data leakage, điểm CV phản ánh đúng khả năng ngoài mẫu	Cawley & Talbot 2010 (chung về selection bias)

Quyết định	Lý do	Tham chiếu
5-fold stratified CV, class_weight=balanced	Dữ liệu ít và mất cân bằng	chuẩn ML
Chạy 4 model song song	So sánh, chưa cố định lựa chọn khi dữ liệu còn ít	–
min_df theo tỷ lệ	Ngưỡng tự co giãn khi ground truth lớn dần	–

8. Hướng cải tiến khi có thêm ground truth

Khi ground truth lên **vài trăm đến vài nghìn dòng** (và cân bằng hơn), dự kiến triển khai + đo lại theo thứ tự dưới. Các ý tưởng **bám sát tài liệu trong REF/**:

Ưu tiên 1 – Đặc trưng từ điển tài chính + phủ định. Ghép thêm các cột đếm hit theo 7 nhóm từ điển đã xây trong Seed_set_Prepate (negative / positive / uncertainty / litigious / strong-modal / weak-modal / constraining), cả dạng tỷ lệ thô lẫn tf-idf weighted; xử lý phủ định cho nhóm positive (cue trong 3 token trước). Căn cứ: *Loughran & McDonald (2011)* – từ điển đa dụng phân loại sai khoảng 74% từ tài chính; từ điển chuyên ngành giảm sai số. *Tetlock (2007)* – nhóm Negative và Weak-modal là hai nhóm tải tín hiệu mạnh nhất.

Ưu tiên 2 – Phương pháp đánh giá & mô hình. Nested-CV tuning siêu tham số; đổi Naive Bayes sang ComplementNB (cho lớp mất cân bằng); ensemble trung bình xác suất 4 model; repeated stratified CV (5 lần x 10 fold) báo cáo mean và độ lệch chuẩn; kiểm định McNemar trước khi kết luận model thắng. Căn cứ: *Cawley & Talbot (2010)* (nested CV), *Rennie et al. (2003)* (ComplementNB), *Dietterich (1998)* (McNemar).

Ưu tiên 3 – Làm sạch không gian đặc trưng. N-gram giới hạn theo mẫu POS (part-of-speech / từ loại) mang sentiment, loại tên riêng; thay số / mã cổ phiếu / phần trăm bằng placeholder; chọn feature có giám sát (chi-square / Delta-IDF) trong fold; thêm đặc trưng SO-PMI cấp bài (tái dùng PMI đã tính ở nhánh Lexicon). Căn cứ: *Turney (2002)* – trích cụm theo mẫu adjective/adverb, tránh proper noun, điểm bài = trung bình semantic orientation. *Yang & Pedersen (1997)* – chi-square / information gain. *Martineau & Finin (2009)* – Delta TF-IDF.

Ưu tiên 4 – Bán giám sát (không cần gán thêm tay). Self-training / EM trên 126k bài chưa nhãn; hoặc mô hình nhãn kiểu Snorkel gộp rule lexicon + weak label PhoBERT; active learning nếu có gán thêm (gán bài uncertainty cao nhất thay vì ngẫu nhiên). Căn cứ: *Nigam et al. (2000)*, *Ratner et al. (2017)*, *Settles (2009)*.

9. Tham khảo

Trong REF/:

- **Loughran, T. & McDonald, B. (2011).** “When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks.” *Journal of Finance* 66(1).
- **Turney, P. D. (2002).** “Thumbs Up or Thumbs Down? Semantic Orientation Applied to Unsupervised Classification of Reviews.” *ACL 2002*.
- **Tetlock, P. C. (2007).** “Giving Content to Investor Sentiment: The Role of Media in the Stock Market.” *Journal of Finance* 62(3).
- **Allen, D. E., McAleer, M. & Singh, A. K. (2015).** “Daily Market News Sentiment and Stock Prices.” *Tinbergen Institute Discussion Paper 15-090/III*.
- Baker, M. & Wurgler, J. – investor sentiment cross-section (bước xây chỉ số).

Ngoài REF/ (dùng cho phần cải tiến):

- Yang, Y. & Pedersen, J. O. (1997). “A Comparative Study on Feature Selection in Text Categorization.” *ICML*.
- Martineau, J. & Finin, T. (2009). “Delta TFIDF: An Improved Feature Space for Sentiment Analysis.” *ICWSM*.
- Rennie, J. D. M. et al. (2003). “Tackling the Poor Assumptions of Naive Bayes Text Classifiers.” *ICML*.
- Cawley, G. C. & Talbot, N. L. C. (2010). “On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation.” *JMLR*.
- Dietterich, T. G. (1998). “Approximate Statistical Tests for Comparing Supervised Classification Learning Algorithms.” *Neural Computation*.
- Nigam, K. et al. (2000). “Text Classification from Labeled and Unlabeled Documents using EM.” *Machine Learning*.
- Ratner, A. et al. (2017). “Snorkel: Rapid Training Data Creation with Weak Supervision.” *VLDB*.
- Settles, B. (2009). “Active Learning Literature Survey.” *Univ. Wisconsin Tech Report*.
- Frank, E. & Hall, M. (2001). “A Simple Approach to Ordinal Classification.” *ECML*.