

Tóm tắt phương pháp Traditional ML

Mục lục

1. Bối cảnh và vị trí của phương pháp	2
2. Dữ liệu	2
3. Đặc trưng (features)	2
3.1. TF-IDF trên n-gram	2
3.2. Đặc trưng từ điển tài chính (lexicon) + phủ định — chỉ dùng cho Random Forest	3
4. Mô hình	4
5. Hướng A — chỉ TF-IDF	4
5.1. Kết quả production	4
5.2. Kiểm định methodology	5
6. Hướng B — +lexicon (Random Forest)	8
6.1. Kết quả production	8
6.2. Xác nhận promote (ground truth 1064, holdout)	8
6.3. Kiểm định methodology trên tập tune	9
7. Kiểm định hạ tầng dùng chung cho cả 2 hướng	10
7.1. Không rõ rở dữ liệu (sanity_checks)	10
7.2. Chất lượng hiệu chỉnh xác suất (calibration_check)	10
8. Hạn chế và hướng tiếp theo	11

1. Bối cảnh và vị trí của phương pháp

Dự án đo sentiment tin tức chứng khoán Việt Nam rồi phân tích tác động lên VN-Index. Việc gán nhãn sentiment cấp bài (positive / negative / neutral) được làm theo **ba hướng độc lập để so sánh**:

1. Lexicon-based (từ điển + công thức) — baseline.
2. **Traditional ML (TF-IDF + classifier)** — **nội dung tài liệu này**.
3. Transfer Learning (fine-tune PhoBERT).

Traditional ML đóng vai **baseline có giám sát, giải thích được**: bag-of-words + TF-IDF + mô hình tuyến tính/cây, để đối chiếu công bằng với Lexicon và Transformer trên cùng một tập ground truth.

Bản thân nhánh Traditional ML lại tách thành **hai hướng con** để so sánh:

- **Hướng A — chỉ TF-IDF**: 4 model production (Logistic Regression, MultinomialNB, ComplementNB, Linear SVM) chạy thuần trên ma trận TF-IDF.
- **Hướng B — +lexicon (Random Forest)**: Random Forest ghép thêm 9 cột đặc trưng từ từ điển tài chính, cộng một ensemble trung bình xác suất 3 model.

2. Dữ liệu

Ground truth	1064 bài gán nhãn tay (tăng từ 152 bài ban đầu)
Phân bố nhãn	negative 295 (27.7%), neutral 493 (46.3%), positive 276 (25.9%)
Tách tune/holdout (cho các kiểm định methodology)	tune 744 bài (neg 206 / neu 345 / pos 193), holdout 320 bài — holdout dùng đúng một lần cho câu hỏi xác nhận lexicon feature (mục 6.2), không tái sử dụng

3. Đặc trưng (features)

3.1. TF-IDF trên n-gram

- N-gram **1–3** trên token tiếng Việt.
- Lọc từ vựng (vocabulary):

- min_df **theo tỷ lệ** số tài liệu ({1-gram: 2%, 2-gram: 1.3%, 3-gram: 1.3%}, sản tối thiểu 2 tài liệu) — không đổi so với thiết kế ban đầu.
- max_df_ratio = 0.85 — bỏ term xuất hiện hơn 85% số bài.
- Bỏ stopwords tiếng Việt; bỏ token dạng số / shape lỗi.
- Từ vựng thực tế trên 1064 bài: **1011 term** (581 unigram / 297 bigram / 133 trigram)

Công thức trọng số dùng đúng **Loughran & McDonald (2011)** cho văn bản tài chính:

$$w_{i,j} = \frac{1 + \log(\text{tf}_{i,j})}{1 + \log(a_j)} \cdot \log \frac{N}{\text{df}_i} \quad \text{nếu } \text{tf}_{i,j} \geq 1$$

- $\text{tf}_{i,j}$: số lần term i xuất hiện trong bài j .
- a_j : tổng số token (trong từ vựng) của bài j — chuẩn hoá độ dài.
- $\log(N/\text{df}_i)$: IDF — term hiếm được coi trọng hơn.

Từ vựng, df, idf và bước chọn top-feature (MAX_FEATURES = 5000) đều được **fit lại riêng trong từng train-fold**, tránh rò rỉ dữ liệu (mục 7.1 kiểm định trực tiếp điều này bằng permutation test).

3.2. Đặc trưng từ điển tài chính (lexicon) + phủ định — chỉ dùng cho Random Forest

9 cột số, ghép cạnh ma trận TF-IDF (np.hstack) trong từng fold, chuẩn hoá z-score trên train-fold:

- 7 cột <category>_prop = số hit / tổng số token, cho 7 nhóm từ điển tài chính (negative, positive, uncertainty, litigious, strong_modal, weak_modal, constraining)
- net_polarity = positive_prop - negative_prop.
- coverage = positive_prop + negative_prop (dùng số hit đã lọc phủ định).

Xử lý phủ định: một hit bị loại nếu có từ phủ định (negation_cue_words.txt) trong cửa sổ 3 token ngay trước nó (NEGATION_WINDOW = 3) áp dụng quy tắc phủ định cho **cả positive lẫn negative**

Khớp cụm nhiều token: nhiều từ trong từ điển dài 3–6 âm tiết, trong khi so khớp đơn-token bỏ sót phần lớn (chỉ 5.6–37.5% mỗi nhóm khớp dưới dạng 1 token). Bản hiện tại dựng mọi n-gram nối _ của chuỗi token tới độ dài cụm dài nhất trong từ điển rồi mới so khớp — đây là 1 trong 3 lỗi đã sửa trước khi feature này được promote

Chỉ random_forest dùng khối feature này trong production; MultinomialNB/ ComplementNB không dùng được vì net_polarity có thể âm (input NB phải không âm); LogisticRegression/SVM có dùng thử nhưng chưa bao giờ có bằng chứng cải thiện đáng tin (mục 6.2).

4. Mô hình

Hướng A (chỉ TF-IDF) chạy 4 model, **Hướng B** chạy Random Forest (+lexicon) và một ensemble — tổng cộng 6 model production:

Model	Cấu hình	Căn cứ lựa chọn
Logistic Regression	$C = 0.1$ (đã tune), <code>class_weight=balanced</code>	Nested-CV: tune 0.614→0.644, CI[+0.011,+0.052] $p=0.000$; xác nhận holdout +0.027, CI loại 0, $p=0.001$
Multinomial Naive Bayes	mặc định	Câu hỏi “thay hẳn ComplementNB” đã test — không khác biệt đáng kể, giữ nguyên
Complement Naive Bayes	mặc định (Rennie et al. 2003)	Bổ sung làm model thứ 4 độc lập, không thay Multinomial NB — xem mục 6.2
Linear SVM	LinearSVC, $C = 0.1$ (đã tune), <code>class_weight=balanced</code> ; xác suất = softmax của decision_function (không phải Platt)	Tune tương tự LogReg. Bỏ Platt vì calibration trên ~40 dòng/inner-fold quá nhiều (mục 7.2); softmax chỉ để xếp hạng, bị loại khỏi ensemble
Random Forest	300 cây, <code>class_weight=balanced</code> , isotonic calibration (cv=3), +lexicon (chỉ production)	Isotonic cải thiện ECE/Brier rõ rệt, đổi lại macro-F1 giảm nhẹ — đánh đổi chấp nhận được (mục 7.2)
Ensemble	Trung bình xác suất LR + NB + RF (RF dùng +lexicon)	Loại SVM vì xác suất không hiệu chỉnh

Đầu ra mỗi bài: nhãn dự đoán + xác suất 3 lớp, và `sentiment_score_ml = P(positive) - P(negative)`.

5. Hướng A — chỉ TF-IDF

5.1. Kết quả production

5-fold stratified CV, single-seed, trên toàn bộ 1064 dòng

Model	Macro F1	Accuracy	F1 negative	F1 neutral	F1 positive
Logistic Regression	0.637	0.651	0.641	0.708	0.563
Complement NB	0.624	0.636	0.651	0.692	0.529
Naive Bayes (Multinomial)	0.621	0.634	0.637	0.696	0.531
SVM	0.612	0.631	0.616	0.694	0.527

Lớp *positive* yếu nhất ở mọi model (F1 0.53–0.56), đúng như quan sát trước đây (từ ít data + hiện tượng “từ tích cực ít giá trị thông tin trong tin tài chính” — Loughran & McDonald 2011, Tetlock 2007).

5.2. Kiểm định methodology

M2.2 — Repeated CV, mean $\pm$ std qua 10 lần lặp:

Model	Macro F1	Accuracy
Logistic Regression	0.645 $\pm$ 0.010	0.659 $\pm$ 0.009
Random Forest (không lexicon)	0.643 $\pm$ 0.010	0.664 $\pm$ 0.009
Complement NB	0.620 $\pm$ 0.005	0.631 $\pm$ 0.005
Multinomial NB	0.617 $\pm$ 0.004	0.629 $\pm$ 0.004
SVM	0.612 $\pm$ 0.011	0.628 $\pm$ 0.010

95% bootstrap CI trên macro-F1 trung bình (B=2000, resample 1064 dòng): Logistic Regression 0.645 [0.617, 0.670]; Random Forest 0.643 [0.616, 0.671]; Complement NB 0.620 [0.592, 0.648]; Multinomial NB 0.617 [0.588, 0.644]; SVM 0.612 [0.585, 0.635].

M2.1 — MultinomialNB vs ComplementNB: delta = +0.003 macro-F1 (nằm trong 1 std $\rightarrow$ nhiều). McNemar: mean_b=15.5, mean_c=17.4, median p=0.705, 0/10 repeat có ý nghĩa $\rightarrow$ **không khác biệt đáng tin**. Khớp với số single-seed production (0.624 vs 0.621, cùng chiều +0.003).

M2.4 — Bootstrap CI trên delta(macro-F1), theo cặp (paired, B=2000):

Cặp	Δ macro-F1	95% CI	p	Kết luận (bootstrap)
LogReg vs Multinomial NB	+0.028	[+0.008, +0.048]	0.008	loại 0

Cặp	Δ macro-F1	95% CI	p	Kết luận (bootstrap)
LogReg vs Complement NB	+0.024	[+0.005, +0.045]	0.019	loại 0
LogReg vs Random Forest	+0.002	[-0.016, +0.020]	0.828	chạm 0
LogReg vs SVM	+0.033	[+0.022, +0.044]	0.000	loại 0
Multinomial NB vs Complement NB	-0.003	[-0.010, +0.002]	0.268	chạm 0
Multinomial NB vs Random Forest	-0.026	[-0.046, -0.006]	0.006	loại 0
Multinomial NB vs SVM	+0.005	[-0.019, +0.028]	0.707	chạm 0
Complement NB vs Random Forest	-0.023	[-0.043, -0.003]	0.022	loại 0
Complement NB vs SVM	+0.009	[-0.015, +0.031]	0.505	chạm 0
Random Forest vs SVM	+0.031	[+0.010, +0.052]	0.011	loại 0

McNemar pairwise (M2.3, trên accuracy) đồng thuận hướng với bootstrap: các cặp có CI loại 0 ở trên cũng là các cặp có sig/N cao (LogReg vs Multinomial NB 7/10, LogReg vs SVM 10/10, Multinomial NB vs Random Forest 9/10, Complement NB vs Random Forest 8/10, Random Forest vs SVM 7/10), ngoại trừ LogReg vs Complement NB (chỉ 6/10 nhưng CI vẫn loại 0).

M2.5 — Nadeau-Bengio corrected variance (điều chỉnh do các fold không độc lập giữa 10 lần lặp) — kết quả quan trọng nhất của mục này:

Cặp	Δ	CI hiệu chỉnh	p hiệu chỉnh	Kết luận
LogReg vs Multinomial NB	+0.028	[-0.000, +0.056]	0.050	chạm 0
LogReg vs Complement NB	+0.025	[-0.007, +0.056]	0.119	chạm 0

Cặp	Δ	CI hiệu chỉnh	p hiệu chỉnh	Kết luận
LogReg vs Random Forest	+0.002	[-0.026, +0.030]	0.883	chạm 0
LogReg vs SVM	+0.033	[+0.013, +0.054]	0.002	loại 0
Multinomial NB vs Complement NB	-0.004	[-0.017, +0.010]	0.582	chạm 0
Multinomial NB vs Random Forest	-0.026	[-0.056, +0.004]	0.091	chạm 0
Multinomial NB vs SVM	+0.005	[-0.027, +0.037]	0.748	chạm 0
Complement NB vs Random Forest	-0.022	[-0.054, +0.009]	0.159	chạm 0
Complement NB vs SVM	+0.009	[-0.025, +0.042]	0.602	chạm 0
Random Forest vs SVM	+0.031	[-0.004, +0.067]	0.085	chạm 0

CI hiệu chỉnh luôn rộng hơn CI bootstrap “ngây thơ” (widen $\times 3.67$ cho mọi model) vì các fold ở 10 lần lặp dùng chung dữ liệu, không thực sự độc lập (Nadeau & Bengio 2003). Điều chỉnh này **lật ngược kết luận** của 5/6 cặp mà bootstrap “ngây thơ” báo là loại 0: LogReg vs Multinomial NB, LogReg vs Complement NB, Multinomial NB vs Random Forest, Complement NB vs Random Forest, Random Forest vs SVM — tất cả chuyển từ “khác biệt thật” sang “không phân biệt được với nhiễu chia fold”.

Kết luận đáng tin cậy nhất của hướng A: trong 10 cặp so sánh, chỉ **một** cặp — **Logistic Regression vs SVM** (+0.033, CI hiệu chỉnh [+0.013,+0.054], $p=0.002$) — còn giữ ý nghĩa sau khi hiệu chỉnh Nadeau-Bengio. Mọi khác biệt khác giữa 4 model production (Logistic Regression, Multinomial NB, Complement NB — Random Forest ở đây chỉ là điểm so sánh methodology, không phải production) đều **chưa đủ bằng chứng để kết luận chắc chắn** ở quy mô 1064 dòng, dù thứ hạng single-seed (mục 5.1) và repeated-mean (bảng M2.2) đều xếp Logistic Regression cao nhất.

6. Hướng B — +lexicon (Random Forest)

6.1. Kết quả production

Cùng bảng 5-fold single-seed, 1064 dòng (RESULTS_SUMMARY.txt):

Model	Macro F1	Accuracy	F1 negative	F1 neutral	F1 positive
Random Forest (+lexicon, isotonic)	0.660	0.676	0.647	0.731	0.600
Ensemble (LR+NB+RF)	0.646	0.661	0.661	0.719	0.558

Random Forest hiện là model đơn lẻ tốt nhất trong toàn bộ 6 model production (0.660, cao hơn Logistic Regression 0.637 ở hướng A), và có F1 lớp positive tốt nhất (0.600) — lớp yếu nhất ở mọi model khác chỉ đạt 0.53–0.56.

6.2. Xác nhận promote (ground truth 1064, holdout)

Đo Δ macro-F1 (random forest) trên tập tune và xác nhận trên tập holdout (thiết kế $\Delta = \text{với_lexicon} - \text{không_lexicon}$, bootstrap CI + p-value):

Ground truth	Thiết kế	Δ tune	Δ holdout
1064 (744/320)	negation cả positive + negative	+0.016, CI [+0.001,+0.033], p=0.039	+0.038, CI [+0.011,+0.066], p=0.004

Hiệu ứng trên holdout còn **lớn hơn** trên tune — không có dấu hiệu overfit vào tập tune. Chỉ random_forest có bằng chứng cải thiện đáng tin; LogReg/ SVM cũng được thử feature này nhưng chưa bao giờ có CI loại 0; MultinomialNB/ComplementNB bị loại khỏi thí nghiệm này vì cột net_polarity có thể âm. Sau khi promote, số production trên 1064 dòng: Random Forest không lexicon (repeated-CV mean, mục 5.2) $0.643 \pm 0.010 \rightarrow$ có lexicon + isotonic (single-seed production) **0.660** — cùng chiều với hiệu ứng đã validate, dù không nên so trực tiếp single-seed với repeated-mean.

6.3. Kiểm định methodology trên tập tune

Tham số mặc định: repeated stratified 5-fold CV, **10 repeats**, bootstrap B=2000, **chỉ trên tập tune (744 dòng)** — đúng theo thiết kế: tập holdout (320 dòng) đã dùng đúng 1 lần cho câu hỏi xác nhận ở mục 6.2, disciplin “check once, không lặp lại” đã tiêu ở đó, nên không chạy lại script này trên holdout. MultinomialNB/ComplementNB bị loại (lý do như mục 6.2).

MACRO-F1: baseline (chỉ TF-IDF) vs +lexicon, trên tập tune:

Model	Baseline	+lexicon	Δ
Logistic Regression	0.633 ± 0.008	0.636 ± 0.009	+0.003
Random Forest	0.637 ± 0.010	0.651 ± 0.006	+0.014
SVM	0.599 ± 0.009	0.600 ± 0.010	+0.002

Bootstrap CI (paired, B=2000):

Model	Δ	95% CI	p	Kết luận
Logistic Regression	+0.003	[-0.014, +0.021]	0.691	chạm 0
Random Forest	+0.014	[-0.002, +0.030]	0.082	chạm 0
SVM	+0.002	[-0.009, +0.013]	0.761	chạm 0

McNemar (baseline vs +lexicon, per repeat): không model nào có sig/N quá 1/10 (Random Forest: mean_b=36.5, mean_c=29.4, median p=0.507, 1/10, pool p=0.006). Nadeau-Bengio corrected cho kết luận cùng chiều (Random Forest $\Delta=+0.014$, CI hiệu chỉnh [-0.016,+0.044], p=0.347 — chạm 0).

Vì sao không chạy trên holdout luôn để kiểm tra cho chắc? Về kỹ thuật hoàn toàn chạy được, nhưng **không nên**. 320 dòng holdout đã bị “tiêu” đúng 1 lần ở mục 6.2 — đó chính là lần cho ra quyết định promote. Script có đổi gì (thêm McNemar, Nadeau-Bengio) không quan trọng, vì **dòng dữ liệu và câu hỏi đặt ra (“lexicon có giúp RF không?”) vẫn y hệt** — nhìn lại lần 2 là đúng kiểu multiple-looks/selection bias mà tune/holdout dựng ra để chặn (Cawley & Talbot 2010, mục 9). Nếu chạy lại mà CI vẫn loại 0 thì cũng không còn tính là “xác nhận độc lập” nữa (đã nhìn dòng này rồi); nếu CI chạm 0 (giống tune) thì không thể phân biệt được đó là hiệu ứng đã yếu đi thật, hay chính lần xác nhận gốc vốn dĩ may mắn. Cách xác nhận sạch duy nhất: có thêm ground truth mới ngoài 1064 dòng hiện tại, dựng holdout mới **chỉ từ phần dữ liệu mới** chưa ai từng nhìn.

7. Kiểm định hạ tầng dùng chung cho cả 2 hướng

7.1. Không rò rỉ dữ liệu (sanity_checks)

Permutation test (Ojala & Garriga 2010): xáo trộn nhãn (quan hệ text–nhãn = 0 theo thiết kế) rồi chạy đúng harness CV leak-free; nếu harness thật sự không rò rỉ, macro-F1 trên nhãn xáo trộn phải rơi về mức ngẫu nhiên. Chạy lại thật ngày 17/09/2026, tham số mặc định (**30 shuffles**, không phải bản smoke-test 5 shuffles trước đó), trên tập tune (744 dòng, mặc định của script):

Block	Real	Shuffled		Gap (std)	p
	macro-F1	mean $\pm$ std	Max shuffled		
naive_bayes, chỉ TF-IDF	0.6021	0.3296 $\pm$ 0.0239	0.3803	11.4	0.0323
random_forest, +lexicon	0.6531	0.2387 $\pm$ 0.0160	0.2716	26.0	0.0323

Cả 2 block: điểm thật vượt qua **toàn bộ** 30 lần xáo trộn ($p=0.0323$ là mức p-value sàn với 30 shuffles, tức 0/30 lần xáo trộn đạt hoặc vượt điểm thật) $\rightarrow$ không có dấu hiệu rò rỉ, kể cả ở nhánh +lexicon có thêm bước chuẩn hoá z-score trong fold (bước có nguy cơ rò rỉ riêng, cũng được kiểm tra độc lập).

Kiểm tra tham chiếu độc lập (sklearn thuần, không dùng code dự án): pipeline TfidfVectorizer + LogisticRegression trong sklearn.Pipeline (refit trong từng fold qua cross_val_predict), trên cùng 744 dòng: macro-F1 = 0.6705, accuracy = 0.6801, vocab 11712 term (không lọc theo thiết kế của dự án, chỉ để tham chiếu). So với Logistic Regression của dự án trên cùng tập tune, baseline hướng B mục 6.3 = 0.633 ± 0.008 — lệch khoảng +0.038, nằm trong ngưỡng ± 0.05 mà script tự đặt ra để coi là “cùng tầm”, không phải dấu hiệu bất thường.

7.2. Chất lượng hiệu chỉnh xác suất (calibration_check)

Biến thể	Macro F1	Brier	ECE
rf_raw (TF-IDF, chưa calibrate)	0.655	0.4692	0.0873
rf_isotonic (TF-IDF, đã calibrate)	0.646	0.4562	0.0245

Biến thể	Macro F1	Brier	ECE
rf_raw_lexicon (+lexicon, chưa calibrate)	0.668	0.4568	0.0821
rf_isotonic_lexicon (+lexicon, đã calibrate)	0.660	0.4403	0.0150
svm_platt	0.611	0.4993	0.0775
svm_softmax	0.612	0.5170	0.0408

(rf_isotonic_lexicon = 0.660 khớp đúng số production ở mục 6.1 — xác nhận chéo giữa 2 file kết quả.)

Kết luận chính — isotonic vẫn có ích sau khi thêm lexicon feature: thêm lexicon feature không làm mất tác dụng của calibration. Cả ở nhánh TF-IDF thuần lẫn nhánh +lexicon, isotonic calibration đều cải thiện rõ rệt cả ECE (0.0873→0.0245 và 0.0821→0.0150) lẫn Brier (0.4692→0.4562 và 0.4568→0.4403), đổi lại macro-F1 giảm nhẹ (0.655→0.646 và 0.668→0.660) — đánh đổi chấp nhận được vì mục tiêu của calibration là xác suất đáng tin (dùng cho sentiment_score_ml ở bước index), không phải tối đa hoá macro-F1.

SVM: bằng chứng trái chiều giữa 2 chỉ số — bỏ Platt cải thiện ECE (0.0775→0.0408) nhưng làm Brier tệ hơn (0.4993→0.5170); macro-F1 gần như không đổi (0.611→0.612). Quyết định giữ margin-softmax (không dùng Platt) vì Platt calibrate trên ~40 dòng/inner-fold quá nhiều để tin cậy, và dù giữ softmax hay Platt thì SVM vẫn bị loại khỏi ensemble (mục 4) vì xác suất của nó không được xem là đã hiệu chỉnh.

8. Hạn chế và hướng tiếp theo

Còn tồn đọng:

- **Ground truth vẫn còn nhỏ**, đặc biệt lớp positive (276/1064, ~55 dòng/fold khi 5-fold) — vẫn là lớp yếu nhất ở mọi model (F1 0.53–0.60). Phần lớn kết luận “model nào hơn model nào” ở hướng A **chưa đủ bằng chứng** sau hiệu chỉnh Nadeau-Bengio (mục 5.2) — cần thêm dữ liệu trước khi chốt.
- **POS-restricted n-gram + chuẩn hoá số** (Turney 2002) — chưa làm, ưu tiên #3.
- **Chọn feature có giám sát trong fold** (χ^2 /Delta-IDF, Yang & Pedersen 1997; Martineau & Finin 2009) — chưa làm, ưu tiên #3.

- **SO-PMI cấp bài** (tái dùng bảng SO đã tính ở nhánh Lexicon_based) — chưa làm, ưu tiên #3.
- **Chất lượng nhãn:** chưa đo inter-annotator agreement (Cohen's κ , cần annotator thứ 2), chưa kiểm tra anchoring bias, chưa thử ordinal loss (neg < neutral < pos) — cần trước khi kết luận chắc model nào đã sát trần.
- **Bán giám sát** (self-training / Snorkel-style label model trên 126k bài chưa nhãn) — chưa làm, ưu tiên thấp nhất.