

Pipeline xây dựng Financial Dictionary và chuẩn bị dữ liệu fine-tune PhoBERT

1 Mục tiêu

Tài liệu này mô tả toàn bộ pipeline từ thời điểm đã có **equity news sạch** và đã xây được **document-term matrix dạng CSR** cho tới bước chuẩn bị dữ liệu để **fine-tune PhoBERT** cho bài toán phân loại sentiment tin tức cổ phiếu.

Pipeline này bám theo tinh thần của:

- **Loughran & McDonald (2011)**: bag-of-words, TF/DF, xây từ điển tài chính riêng theo ngữ cảnh domain.
- Hướng triển khai thực tế cho project hiện tại: tạo **financial dictionary / equity dictionary**, sinh **sentiment feature**, tạo **label**, rồi đưa vào mô hình **PhoBERT fine-tune**.

2 Điểm xuất phát hiện tại

Hiện tại đã có:

- **equity_news_df**: tập tin equity news đã được làm sạch.
- Cột text chính để phân tích:
 - **title**
 - **description**
 - hoặc cột ghép như **des-title**
- Dữ liệu đã được tokenize tiếng Việt.
- Đã xây được:
 - **CountVectorizer**
 - **document-term matrix dạng CSR sparse matrix**

Điều này có nghĩa là phần **bag-of-words nền tảng** đã hoàn thành.

3 Tổng quan pipeline từ đây đến PhoBERT

Pipeline tổng quát:

1. Xây **TF / DF statistics** từ CSR matrix
2. Chọn **candidate terms**
3. Review thủ công để xây **Financial Dictionary v1**
4. Tính **lexicon-based features** cho từng bài báo
5. Tạo **sentiment label / sentiment score** sơ bộ
6. Rà soát và làm sạch bộ nhãn
7. Chuẩn bị tập dữ liệu huấn luyện cho **PhoBERT**
8. Fine-tune PhoBERT cho bài toán sentiment classification
9. Xuất xác suất lớp và suy ra **sentiment_score** cuối cùng
10. Gộp lên **ticker-date** để phục vụ firm-day analysis

4 Bước 1 - Tính TF và DF từ CSR matrix

Sau khi có document-term matrix, bước tiếp theo là xây thống kê từ vựng cho toàn bộ corpus equity news.

4.1 TF là gì

TF (Term Frequency) là tổng số lần một từ xuất hiện trong toàn bộ corpus hoặc trong từng document.

Ví dụ:

- từ 1ẽ xuất hiện 2,000 lần trong toàn bộ equity news
=> TF = 2000

4.2 DF là gì

DF (Document Frequency) là số lượng document có chứa từ đó ít nhất một lần.

Ví dụ:

- từ 1ẽ xuất hiện trong 800 bài báo
=> DF = 800

4.3 Vai trò của TF/DF

TF và DF giúp trả lời:

- Từ nào xuất hiện nhiều?
- Từ nào phổ rộng trên nhiều bài?
- Từ nào quá hiếm để đưa vào dictionary?
- Từ nào quá phổ biến nhưng có thể không mang sentiment?

4.4 Output của bước này

Tạo một bảng thống kê dạng:

- term
- tf
- df
- df_ratio
- avg_tf_per_doc

Bảng này là đầu vào chính để xây **financial dictionary**.

5 Bước 2 - Chọn candidate terms

Không nên review toàn bộ vocabulary thô vì số lượng token thường rất lớn và nhiều token không có giá trị.

5.1 Quy tắc lọc sơ bộ

Có thể áp dụng một số rule như:

- Chỉ giữ các từ có df $\geq$ ngưỡng tối thiểu
- Loại các từ quá hiếm
- Loại token lỗi, token rác
- Loại số thuần túy
- Loại stopwords quá chung nếu cần
- Loại các token không phản ánh nội dung tài chính

5.2 Mục tiêu của bước này

Mục tiêu là tạo ra một danh sách **candidate terms** đủ gọn để có thể:

- đọc thủ công
- gán nhóm sentiment
- xây dictionary v1

6 Bước 3 - Xây Financial Dictionary v1

Đây là bước quan trọng nhất theo tinh thần Loughran & McDonald (2011).

6.1 Ý tưởng chính

Không dùng sentiment dictionary chung một cách máy móc.

Thay vào đó, xây một **từ điển riêng cho equity news** dựa trên chính corpus của mình.

6.2 Cách gán nhóm từ

Review thủ công danh sách candidate terms và gán mỗi từ vào một nhóm như:

- positive
- negative
- uncertainty
- litigious
- neutral/remove

Có thể thêm:

- strong_modal

- weak_modal

nếu muốn bám sát hơn với hướng mở rộng của Loughran & McDonald.

6.3 Ví dụ

6.3.1 Negative

- thua_lỗ
- suy_giảm
- đình_chỉ
- xử_phạt
- vi_phạm

6.3.2 Positive

- tăng_trưởng
- khởi_sắc
- hồi_phục
- mở_rộng
- cải_thiện

6.3.3 Uncertainty

- rủi_ro
- có_thể
- dự_kiến
- khả_năng
- biến_động

6.3.4 Litigious

- khởi_kiến
- tranh_chấp
- xử_phạt
- điều_tra
- vi_phạm_pháp_lý

6.4 Output của bước này

Một bảng dictionary dạng:

- term
- category
- keep_flag
- note

Ví dụ:

term	category	keep_flag	note
thua_lỗ	negative	1	tone tiêu cực rõ
tăng_trưởng	positive	1	tone tích cực rõ
cổ_phiếu	neutral	0	từ chủ đề, không phải sentiment
doanh_nghiệp	neutral	0	từ quá chung

7 Bước 4 - Mở rộng dictionary

Sau khi có dictionary v1, nên mở rộng thêm bằng:

- biến thể từ
- cụm từ gần nghĩa
- cách viết khác nhau
- cụm từ chuyên ngành equity

Ví dụ:

- lỗ, thua_lỗ, lỗ_ròng
- tăng, tăng_mạnh, tăng_trưởng
- điều_tra, thanh_tra, xử_phạt

Mục tiêu là tăng khả năng bao phủ của dictionary nhưng vẫn giữ đúng ngữ cảnh tài chính.

8 Bước 5 - Tính lexicon-based features cho từng bài báo

Sau khi đã có financial dictionary, áp dictionary lên từng bài báo trong `equity_news_df`.

8.1 Các biến nên tính

Cho mỗi bài báo, tính:

- `pos_count`
- `neg_count`
- `uncertainty_count`
- `litigious_count`

Ngoài ra có thể tính thêm:

- `title_length`
- `description_length`
- `total_token_count`

8.2 Các chỉ số chuẩn hóa

Có thể tạo thêm:

- `pos_ratio` = `pos_count` / `total_token_count`
- `neg_ratio` = `neg_count` / `total_token_count`
- `unc_ratio` = `uncertainty_count` / `total_token_count`
- `lit_ratio` = `litigious_count` / `total_token_count`

8.3 Sentiment score sơ bộ

Một công thức đơn giản, dễ diễn giải:

$$\text{sentiment_score} = \frac{\text{pos_count} - \text{neg_count}}{\text{pos_count} + \text{neg_count}}$$

Quy ước:

- nếu mẫu số bằng 0 thì `sentiment_score` = 0

Ý nghĩa:

- gần 1 -> rất positive
- gần -1 -> rất negative
- gần 0 -> neutral hoặc tín hiệu yếu

9 Bước 6 - Sinh label sentiment sơ bộ

Từ `sentiment_score`, có thể tạo `sentiment_label` sơ bộ:

- `positive` nếu `sentiment_score > ngưỡng dương`
- `negative` nếu `sentiment_score < ngưỡng âm`
- `neutral` nếu nằm giữa hai ngưỡng

Ví dụ:

- `positive` nếu `score > 0.1`
- `negative` nếu `score < -0.1`
- `neutral` nếu `-0.1 <= score <= 0.1`

9.1 Lưu ý quan trọng

Label sinh từ dictionary chỉ nên được xem là:

- `weak label`
- hoặc `pseudo-label`

Không nên coi đây là ground truth cuối cùng nếu muốn fine-tune model mạnh như PhoBERT.

10 Bước 7 - Làm sạch bộ nhãn trước khi train

Để mô hình học đúng, cần rà soát bộ nhãn trước khi fine-tune.

10.1 Cách làm thực tế

- Lấy mẫu ngẫu nhiên các bài đã gán `positive`
- Lấy mẫu ngẫu nhiên các bài đã gán `negative`
- Lấy mẫu ngẫu nhiên các bài đã gán `neutral`
- Đọc thủ công và kiểm tra mức độ hợp lý

10.2 Mục tiêu

- loại các bài bị gán sai rõ ràng
- chỉnh lại dictionary nếu cần
- tăng chất lượng nhãn

10.3 Kết quả mong muốn

Sau bước này, có một tập dữ liệu **semi-clean labels** đủ tốt để dùng cho supervised training.

11 Bước 8 - Chuẩn bị dữ liệu cho PhoBERT

Sau khi có `sentiment_label`, chuẩn bị dữ liệu huấn luyện cho mô hình PhoBERT.

11.1 Input text

Input nên dùng:

- `title + description`

Lý do:

- `title` thường chứa tín hiệu sentiment mạnh
- `description` bổ sung ngữ cảnh
- dùng cả hai thường tốt hơn chỉ dùng một trường

Có thể ghép theo dạng:

`title [SEP] description`

hoặc chỉ cần nối chuỗi thông thường.

11.2 Label huấn luyện

Sử dụng:

- `negative`
- `neutral`
- `positive`

Đây là bài toán **3-class classification**.

11.3 Chia tập dữ liệu

Nên chia thành:

- `train`
- `validation`
- `test`

Khuyến nghị:

- chia theo **thời gian** nếu muốn tránh look-ahead bias
- hoặc chia stratified nếu trước mắt mới cần baseline classification

12 Bước 9 - Fine-tune PhoBERT

12.1 PhoBERT là gì

PhoBERT là một mô hình Transformer tiền huấn luyện cho tiếng Việt, phù hợp cho các bài toán NLP như:

- phân loại văn bản
- sentiment analysis
- sequence classification

12.2 Đầu vào và đầu ra

12.2.1 Input

- `text = title + description`

12.2.2 Output

Với mỗi bài báo, PhoBERT sẽ trả ra 3 xác suất:

- `p_negative`
- `p_neutral`
- `p_positive`

Từ đó:

- lớp có xác suất lớn nhất = `sentiment_label_pred`

12.3 Suy ra sentiment score từ PhoBERT

Có thể định nghĩa:

$$\text{sentiment_score_model} = p(\text{positive}) - p(\text{negative})$$

Ý nghĩa:

- dương -> thiên positive
- âm -> thiên negative
- gần 0 -> neutral

13 Bước 10 - Đánh giá mô hình

Các chỉ số nên dùng:

- accuracy
- macro F1
- precision
- recall
- confusion matrix

Nếu mục tiêu internship là accuracy $\geq 80\%$, thì vẫn nên báo thêm macro F1 để tránh trường hợp accuracy cao nhưng model thiên lệch vào lớp lớn.

14 Bước 11 - Tạo output cuối cùng cho từng bài báo

Sau khi infer bằng PhoBERT, mỗi bài báo nên có:

- publication_date
- title
- description
- keywords_norm
- domain_norm
- sentiment_label_pred
- p_negative
- p_neutral
- p_positive
- sentiment_score_model

15 Bước 12 - Gộp lên firm-day

Sau khi có sentiment của từng bài, bước tiếp theo là map bài báo về ticker rồi gộp theo ticker + date.

Các biến firm-day nên tính:

- news_count
- mean_sentiment
- weighted_sentiment
- abs_sentiment

Sau đó merge với **historical_price features** để kiểm tra:

- ret_1
- ret_3
- ret_5
- abn_vol
- rolling_std_ret_20
- intraday_range_ratio

16 Flow ngắn gọn để đưa vào report

Equity news sạch -> tokenize -> CSR document-term matrix -> TF/DF statistics -> candidate term selection -> Financial Dictionary v1 -> lexicon-based sentiment features -> weak labels -> review and refinement -> PhoBERT fine-tuning -> predicted sentiment probabilities -> article-level sentiment score -> firm-day aggregation

17 Kết luận

Trong pipeline này, phần **bag-of-words + TF/DF + financial dictionary** đóng vai trò tạo nền tảng domain knowledge cho equity news tiếng Việt. Sau đó, dictionary-based sentiment được dùng để sinh weak labels và hỗ trợ hiểu dữ liệu. Cuối cùng, PhoBERT được fine-tune trên bộ dữ liệu đã được chuẩn bị để học ngữ cảnh tốt hơn và tạo ra sentiment predictions mạnh hơn so với phương pháp từ điển thuần túy.